Time Series 1: Data Preparation and Decomposition

การบรรยายที่ 7: trend, seasonality, moving averages และ classical decomposition

อาจารย์สิปปนนท์ กิติมูล

ภาคการศึกษาที่ 1/2569

เมื่อลำดับของข้อมูลมีความหมาย: จาก regression สู่ time series

ครึ่งเทอมแรกวางเงื่อนไขไว้ข้อหนึ่งที่คาบนี้จะละเมิด

สิ่งที่ linear regression สมมติไว้

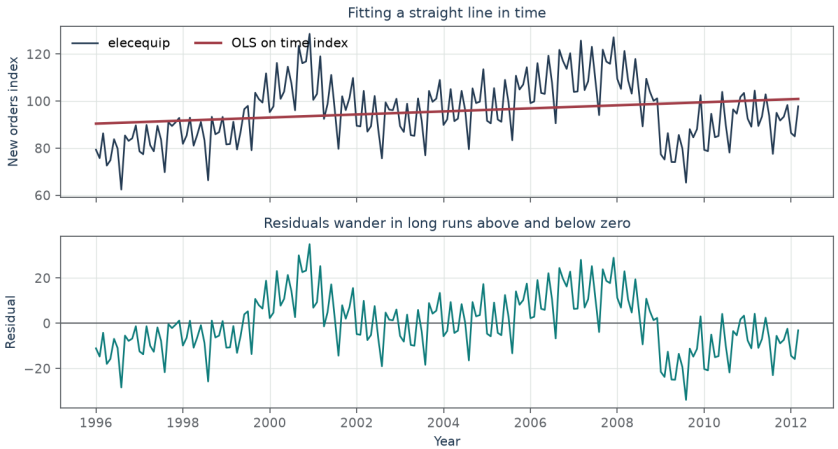
- ε_i เป็นอิสระต่อกัน
- $\text{Var}(\varepsilon_i)$ คงที่
- ความสัมพันธ์เป็นเชิงเส้น

ข้อมูลที่เก็บตามเวลา

- ค่าที่ใกล้กันในเวลามักใกล้กันในขนาด
- ความผันผวนมักโตตามระดับของข้อมูล
- ฤดูกาลทำให้รูปแบบวนซ้ำ

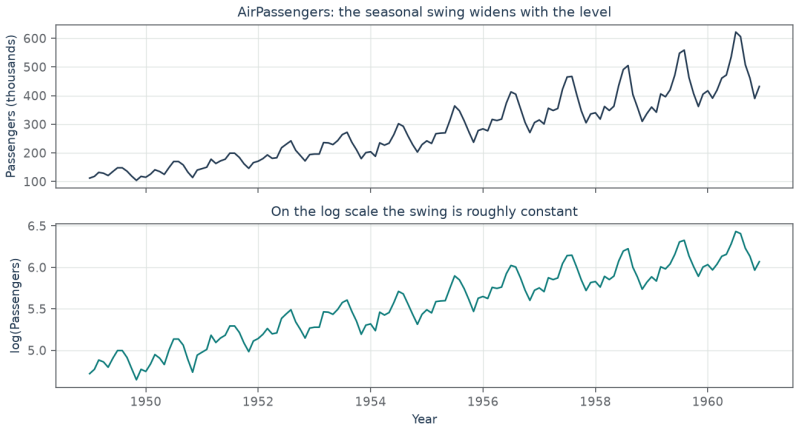
คาบนี้ไม่ได้ทิ้ง regression แต่เปลี่ยนคำถามจาก "X อธิบาย Y อย่างไร" เป็น "อดีตของ Y บอกอะไรเกี่ยวกับอนาคตของ Y"

ลาก OLS ผ่าน time index แล้วดู residuals



ข้อมูล `elecequip`: ดัชนีคำสั่งซื้อใหม่ของอุตสาหกรรมอุปกรณ์ไฟฟ้าในกลุ่มยูโร รายเดือน 1996–2012

ปัญหาที่สอง: ความผันผวนโตตามระดับของข้อมูล



`AirPassengers`: จำนวนผู้โดยสารสายการบินระหว่างประเทศรายเดือน 1949–1960 หน่วยพันคน

เป้าหมายของคาบนี้

หลังจบคาบบรรยาย 2 ชั่วโมง นักศึกษาควรสามารถ

1. เตรียมข้อมูล time series ด้วย `DatetimeIndex`, frequency และ `resample` ได้
2. แยก trend, seasonality และ cycle ออกจากกันได้
3. เลือกระหว่าง additive และ multiplicative decomposition จากหลักฐานในข้อมูลได้
4. คำนวณ moving average ทั้ง m-MA และ $2 \times m$-MA ได้
5. ทำ classical decomposition ทีละขั้นและอธิบายข้อจำกัดของมันได้
6. วัดความแรงของ trend และ seasonality ด้วย F_T และ F_S ได้
7. สร้าง forecast จาก decomposition และวัดความแม่นยำเทียบกับ benchmark ได้

การเตรียมข้อมูลอนุกรมเวลา

ก่อนจะ model อะไรได้ ดัชนีเวลาต้องถูกต้องเสียก่อน

สัญกรณ์: ข้อมูลหนึ่งชุดเรียงตามเวลา

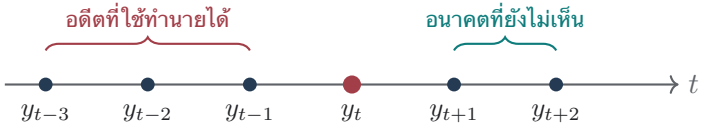
$$\ldots,\ y_{t-2},\ y_{t-1},\ y_t,\ y_{t+1},\ y_{t+2},\ \ldots$$

- t คือ **time index** ไม่ใช่ค่าที่วัดได้ แต่เป็นตำแหน่งบนแกนเวลา
- T คือจำนวนข้อมูลทั้งหมด $y_1, y_2, \ldots, y_T$
- **lag k** ของ y_t คือ y_{t-k} นั่นคือค่าที่ห่างออกไปในอดีต k คาบ
- m คือ **seasonal period** เช่น $m = 12$ สำหรับข้อมูลรายเดือน $m = 4$ สำหรับรายไตรมาส

ตัวอย่าง

ถ้า t คือเดือนมีนาคม 2012 แล้ว lag 12 ของ y_t คือค่าของเดือนมีนาคม 2011

ลำดับคือข้อมูล ไม่ใช่แค่การจัดเรียง



กฎที่ห้ามละเมิด

ห้าม shuffle ข้อมูล time series และห้ามแบ่ง training/test แบบสุ่ม เพราะการทำเช่นนั้นคือการให้ model เห็นอนาคตก่อนทำนายอดีต ผลที่ได้จะดีเกินจริงและใช้ไม่ได้จริง

อ่านไฟล์ให้ index เป็นเวลาตั้งแต่ต้น

```
import pandas as pd

data = pd.read_csv(
    "elecequip.csv",
    parse_dates=["time"],      # column to convert to datetime
    date_format="%Y-%m",       # how the text is formatted in the file
    index_col="time",          # column to use as the index
)
y = data["value"]
```

`date_parser` ถูกถอดออกแล้ว

ตัวอย่างเก่าจำนวนมากใช้ `date_parser=parser` ซึ่ง pandas เอาออกตั้งแต่รุ่น 2.0 และ `pd.datetime` ก็ถูกถอดออกเช่นกัน ให้ใช้ `date_format` แทน

Frequency คือคำสัญญาว่าไม่มีคาบไหนหายไป

```
print(y.index.inferred_freq)   # 'MS' = month start
y = y.asfreq("MS")             # force one row per month
print(y.isna().sum())          # a missing period now shows up as NaN
```

รหัส	ความหมาย	ใช้กับ
D	รายวัน	ข้อมูลอุณหภูมิรายวัน
MS / ME	ต้นเดือน / สิ้นเดือน	ข้อมูลรายเดือน
QS	ต้นไตรมาส	ข้อมูลรายไตรมาส
YS	ต้นปี	ข้อมูลรายปี

asfreq ไม่ได้เติมค่าให้ แต่ทำให้คาบที่หายไป ปรากฏตัว เป็น NaN ซึ่งเป็นสิ่งที่เราต้องการ

resample เปลี่ยนความถี่ของข้อมูล

```
# CM_temp is daily data, 7882 rows
monthly = data["MaxTemp"].resample("ME").mean()
```

Downsampling

รายวัน → รายเดือน ต้องเลือก aggregation ว่า mean, sum, max หรือ last ตามความหมายของตัวแปร

"M" ใช้ไม่ได้แล้ว

pandas รุ่นใหม่ตอบ ValueError ถ้าเขียน resample("M") ต้องระบุให้ชัดว่า "ME" (สิ้นเดือน) หรือ "MS" (ต้นเดือน)

อุณหภูมิสูงสุดรายวันเฉลี่ยเป็นรายเดือนใช้ mean แต่ยอดขายรายวันรวมเป็นรายเดือนต้องใช้ sum

ตรวจข้อมูลก่อน แล้วค่อย model

สิ่งที่ต้องตรวจ	เหตุผล
index เป็น datetime หรือยัง	ถ้าเป็นข้อความ การเรียงลำดับจะเป็นแบบตัวอักษร ไม่ใช่ตามเวลา
คาบที่หายไป	`2010-03` ที่ไม่มีในไฟล์ ต่างจาก `2010-03` ที่มีค่าเป็น NaN
ปีแรกและปีสุดท้ายครบหรือไม่	`CM_temp` จบที่เดือนกรกฎาคม 2019 ปีสุดท้ายจึงมีเพียง 7 เดือน
ความถี่สม่ำเสมอหรือไม่	moving average และ decomposition สมมติว่าระยะห่างเท่ากันทุกคาบ
ค่าผิดปกติที่เกิดจากการบันทึก	ศูนย์ที่แปลว่า “ไม่มีข้อมูล” จะถูกนับเป็นค่าจริงถ้าไม่จัดการก่อน

ปีที่ไม่ครบไม่ใช่ข้อผิดพลาด แต่ต้องรู้ตัว เพราะค่าเฉลี่ยรายปีของปีนั้นจะเทียบกับปีอื่นไม่ได้

รูปแบบที่ต้องมองหาในกราฟ

trend, seasonality และ cycle เป็นคนละสิ่งกัน

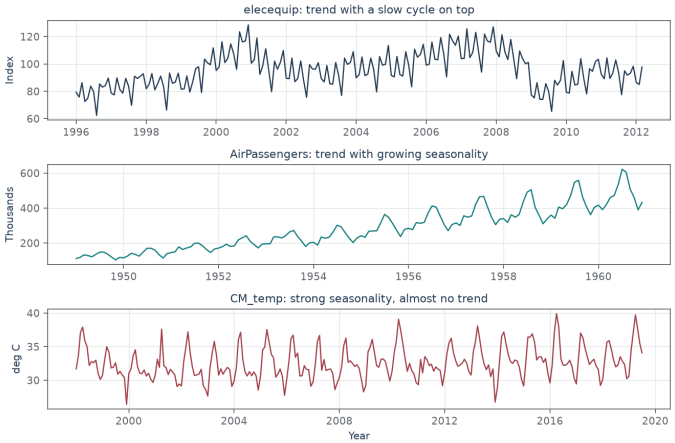
สามรูปแบบที่ต้องแยกให้ออก

รูปแบบ	นิยาม	ตัวอย่าง
Trend	การเพิ่มหรือลดในระยะยาว ไม่จำเป็นต้องเป็นเส้นตรง	จำนวนผู้โดยสารที่โตขึ้นตลอดทศวรรษ
Seasonality	รูปแบบที่วนซ้ำด้วย **คาบคงที่และรู้ล่วงหน้า**	อากาศร้อนที่สุดในเดือนเมษายนทุกปี
Cycle	การขึ้นลงที่ไม่มีคาบตายตัว ยาวกว่าหนึ่งปีและคาดเดาเวลาไม่ได้	วัฏจักรเศรษฐกิจ วิกฤตปี 2008

ความสับสนที่พบบ่อยที่สุด

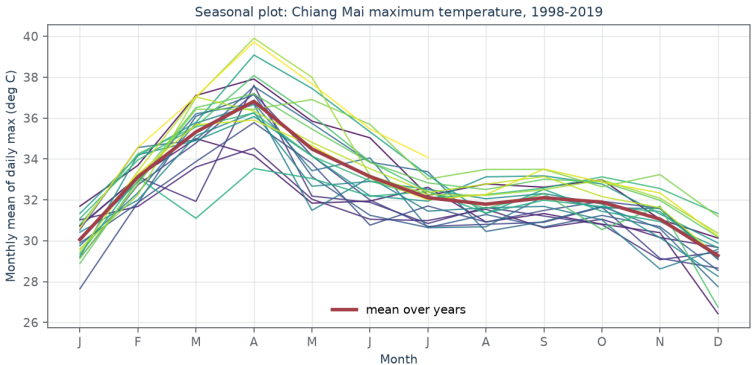
seasonality กับ cycle ไม่ใช่สิ่งเดียวกัน seasonality มีความยาวคาบคงที่และผูกกับปฏิทิน ส่วน cycle ยาวไม่เท่ากันในแต่ละรอบ decomposition แยกเฉพาะ seasonality ออกมา ส่วน cycle จะถูกนับรวมอยู่ใน trend

ข้อมูลสามชุด สามรูปร่าง



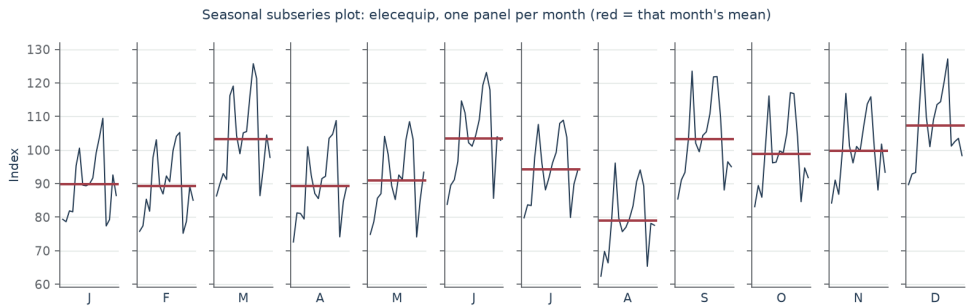
elecequip มี trend และ cycle ชัด (สังเกตการทรุดปี 2008), AirPassengers มี trend พร้อม seasonality ที่ขยายตัว, CM_temp แทบไม่มี trend แต่ seasonality แรงมาก

Seasonal plot วางทุกปีทับกันเพื่อให้เห็นฤดูกาล



เส้นสีอ่อนคือปีหลัง ๆ อุณหภูมิเฉลี่ยสูงสุดอยู่ที่เดือนเมษายน 36.8 องศา และต่ำสุดที่เดือนธันวาคม 29.3 องศา

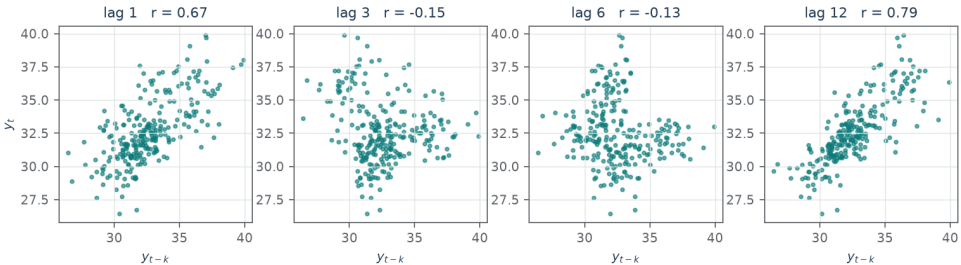
Subseries plot ให้แต่ละเดือนมีกราฟของตัวเอง



อ่านอย่างไร

เส้นแนวนอนสีแดงคือค่าเฉลี่ยของเดือนนั้น ความต่างระหว่างเส้นแดงคือ seasonality ส่วนความชันภายในแต่ละช่องคือ trend ที่เกิดขึ้น ภายในเดือนเดียวกันข้ามปี

Lag plot: seasonality โผล่ออกมาที่ lag 12



lag 1: $r = +0.67$	ค่าที่ติดกันสัมพันธ์กันสูง
lag 12: $r = +0.79$	เดือนเดียวกันของปีก่อนทำนายได้ดีที่สุด นี่คือลายเซ็นของ seasonality

ในคาบที่ 9 เราจะสรุปกราฟทั้งชุดนี้ให้เหลือรูปเดียวด้วย autocorrelation function (ACF)

Check yourself: จำแนกรูปแบบให้ถูก

สถานการณ์	trend, seasonality หรือ cycle?
ยอดขายเสื้อกันหนาวสูงทุกเดือนธันวาคม	?
ราคาที่ดินที่เพิ่มขึ้นตลอด 20 ปี	?
จำนวนนักท่องเที่ยวที่ทรุดตัวช่วงโรคระบาดแล้วฟื้น	?
ปริมาณการใช้ไฟฟ้าที่สูงในช่วงบ่ายทุกวัน	?

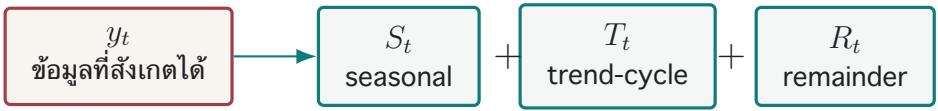
คำถามที่ใช้ตัดสิน

“คาบของมันคงที่และรู้ล่วงหน้าหรือไม่” ถ้าใช่คือ seasonality ถ้าขึ้นลงแต่ไม่รู้ว่าเมื่อไรคือ cycle

Decomposition: แยกอนุกรมเวลาออกเป็นส่วนประกอบ

$y_t = S_t + T_t + R_t$ หรือ $y_t = S_t \times T_t \times R_t$

แนวคิด: มองอนุกรมเวลาเป็นผลรวมของสามส่วน



- S_t **seasonal component**: รูปแบบที่วนซ้ำด้วยคาบ m
- T_t **trend-cycle component**: การเคลื่อนที่ระยะยาว รวม cycle ไว้ด้วย จึงมักเรียกสั้น ๆ ว่า trend
- R_t **remainder component**: สิ่งที่เหลือหลังหักสองส่วนแรกออก

เป้าหมายคือความเข้าใจ ไม่ใช่แค่การทำนาย เมื่อแยกส่วนได้แล้วเราจะตอบได้ว่าการเปลี่ยนแปลงที่เห็นเป็นเรื่องฤดูกาลปกติหรือเป็นการเปลี่ยนแปลงจริง

สองรูปแบบของ decomposition

Additive

$$y_t = S_t + T_t + R_t$$

ขนาดของการแกว่งตามฤดูกาล **คงที่** ไม่ว่าระดับของข้อมูลจะสูงหรือต่ำ

Multiplicative

$$y_t = S_t \times T_t \times R_t$$

ขนาดของการแกว่ง **โตตามระดับ** ของข้อมูล S_t จึงเป็นสัดส่วน ไม่ใช่จำนวน

ทั้งสองแบบเชื่อมกันด้วย logarithm

$$y_t = S_t \times T_t \times R_t \quad \Longleftrightarrow \quad \log y_t = \log S_t + \log T_t + \log R_t$$

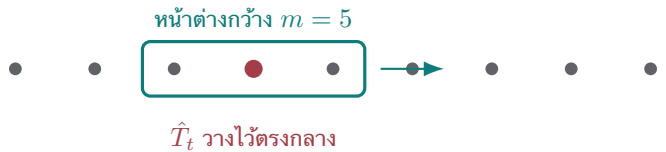
การ decompose แบบ multiplicative จึงเท่ากับการ decompose แบบ additive บนข้อมูลที่ใส่ log แล้ว

Moving average: เครื่องมือประมาณ trend

ค่าเฉลี่ยเคลื่อนที่ลบ seasonality และ noise ออก เหลือไว้แต่การเคลื่อนที่ระยะยาว

Moving average อันดับ m

$$\hat{T}_t = \frac{1}{m} \sum_{i=-k}^{k} y_{t+i}, \qquad m = 2k + 1$$



- เรียกว่า m-MA และเรียกว่า centred เพราะผลลัพธ์วางที่กึ่งกลางหน้าต่าง
- ค่าที่ได้เรียบกว่าข้อมูลเดิม เพราะการเฉลี่ยหักล้างความผันผวนที่สุ่มขึ้นลง
- ต้นและปลายอนุกรมจะไม่มีค่า เพราะหน้าต่างยื่นออกนอกข้อมูล

ตัวอย่าง: 5-MA บน elecequip

เดือน	value	5-MA
1996-01	79.35	–
1996-02	75.78	–
1996-03	86.32	77.78
1996-04	72.60	78.67
1996-05	74.86	79.48
1996-06	83.81	74.70
1996-07	79.80	77.26
1996-08	62.41	78.91

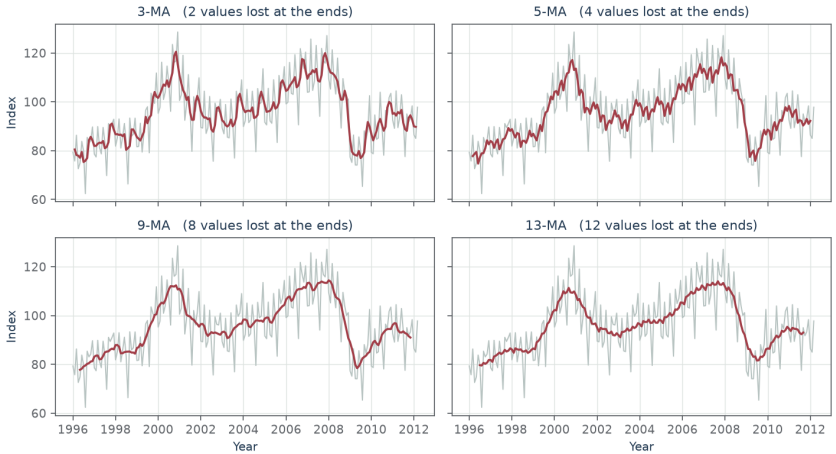
ค่าแรกมาจากไหน

$$\frac{79.35 + 75.78 + 86.32 + 72.60 + 74.86}{5} = 77.78$$

ปลายทั้งสองข้างหายไป

$m = 5$ ทำให้เสียข้อมูล 2 ค่าที่ต้นและ 2 ค่าที่ปลาย โดยทั่วไปคือ k ค่าต่อข้าง

m ยิ่งใหญ่ เส้นยิ่งเรียบ และข้อมูลปลายยิ่งหาย



ต้องเลือก m ให้พอดี เล็กเกินไปจะเหลือ seasonality ปนอยู่ใน trend ใหญ่เกินไปจะกลืนการเปลี่ยนแปลงจริงที่เราสนใจ

ปัญหาเมื่อ m เป็นเลขคู่

m คี่

หน้าต่างมีจุดกึ่งกลางที่เป็นเวลาจริง เช่น $m = 5$ วางผลลัพธ์ที่จุดที่ 3 ได้พอดี

m คู่

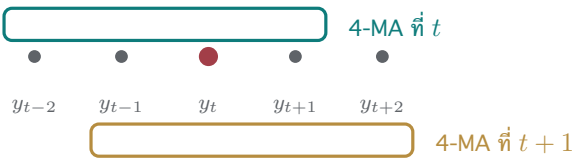
หน้าต่างของ $m = 4$ มีกึ่งกลางอยู่ “ระหว่าง” สองจุดเวลา ผลลัพธ์จึงไม่ตรงกับคาบใดเลย

แต่ข้อมูลจริงมัก seasonal ด้วยคาบเลขคู่

รายไตรมาสมี $m = 4$ และรายเดือนมี $m = 12$ ซึ่งเป็นเลขคู่ทั้งคู่ เราจึงต้องหาวิธีทำให้ค่าเฉลี่ยกลับมาอยู่ตรงกลางอีกครั้ง

ต้องเลือก m เท่ากับคาบของฤดูกาลเสมอ เพราะการเฉลี่ยครบหนึ่งรอบฤดูกาลพอดีคือสิ่งที่ทำให้ seasonality หักล้างกันหมด

$2 \times m$-MA: เฉลี่ยซ้ำอีกครั้งเพื่อดึงกลับเข้ากึ่งกลาง



เฉลี่ยสองแถบนี้แล้ววางผลลัพธ์ที่ t

$$\begin{aligned}\hat{T}_t &= \frac{1}{2}\left[\frac{1}{4}(y_{t-2}+y_{t-1}+y_t+y_{t+1}) + \frac{1}{4}(y_{t-1}+y_t+y_{t+1}+y_{t+2})\right] \\ &= \tfrac{1}{8}y_{t-2} + \tfrac{1}{4}y_{t-1} + \tfrac{1}{4}y_t + \tfrac{1}{4}y_{t+1} + \tfrac{1}{8}y_{t+2}\end{aligned}$$

ผลลัพธ์คือค่าเฉลี่ยถ่วงน้ำหนักที่สมมาตรรอบ t โดยปลายทั้งสองข้างได้น้ำหนักครึ่งเดียว

ตัวอย่าง: 4-MA และ 2×4-MA บน elecequip รายไตรมาส

ไตรมาส	value	4-MA	2×4
1996Q1	80.48	–	–
1996Q2	77.09	–	–
1996Q3	75.87	79.78	79.97
1996Q4	85.67	80.15	80.91
1997Q1	81.97	81.67	82.37
1997Q2	83.15	83.08	83.76
1997Q3	81.52	84.44	85.04

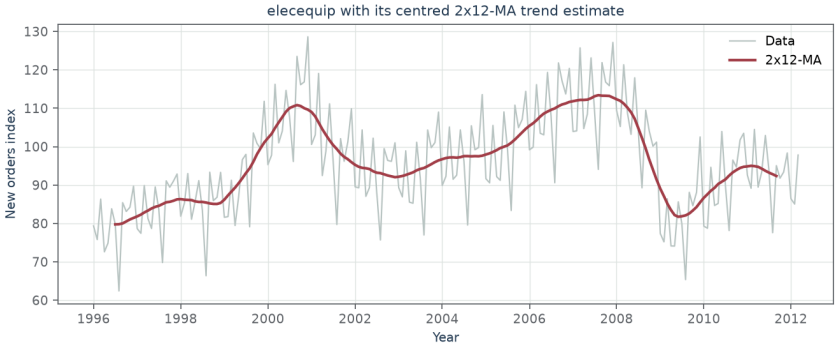
ตรวจเลขด้วยมือ

$$\text{4-MA}_{\text{Q3}} = \tfrac{1}{4}(80.48 + 77.09 + 75.87 + 85.67) = 79.78$$

$$2 \times \text{4-MA}_{\text{Q3}} = \tfrac{1}{2}(79.78 + 80.15) = 79.97$$

สรุปกฎ: $\hat{T}_t$ ใช้ m-MA เมื่อ m เป็นเลขคี่ และใช้ $2 \times m$-MA เมื่อ m เป็นเลขคู่

2×12-MA บนข้อมูลรายเดือน



ราคาที่ต้องจ่าย

2×12-MA ทำให้เสียข้อมูล 6 ค่าที่ต้นและอีก 6 ค่าที่ปลายอนุกรม ค่าที่หายไปที่ ปลาย คือค่าที่ใกล้ปัจจุบันที่สุด ซึ่งเป็นค่าที่การพยากรณ์ต้องการมากที่สุด

Classical decomposition

สี่ขั้นตอนที่คำนวณด้วยมือได้ทั้งหมด

Additive decomposition: สี่ขั้นตอน



ขั้นที่ 1 อย่างละเอียด

เลือก m เท่ากับคาบของฤดูกาล แล้วคำนวณ

$$\hat{T}_t = \begin{cases} m\text{-MA} & \text{เมื่อ } m \text{ เป็นเลขคี่} \\ 2 \times m\text{-MA} & \text{เมื่อ } m \text{ เป็นเลขคู่} \end{cases}$$

ขั้นที่ 3: ค่าเฉลี่ยของแต่ละหน่วยฤดูกาล

คำนวณอย่างไร

สำหรับข้อมูลรายเดือน ให้เฉลี่ยค่า $y_t - \hat{T}_t$ ที่ตกในเดือนเดียวกันทุกปี

$$S_1 = \text{ค่าเฉลี่ยของทุกเดือนมกราคม}, \quad S_2 = \text{ค่าเฉลี่ยของทุกเดือนกุมภาพันธ์}, \quad \ldots$$

แล้วปรับให้ผลรวมเป็นศูนย์

$$\hat{S}_j = S_j - \bar{S}, \qquad \bar{S} = \frac{1}{12}\sum_{i=1}^{12} S_i$$

ถ้าไม่ปรับ ค่าเฉลี่ยของ seasonal component จะไม่เป็นศูนย์ และส่วนที่เกินจะไปบวกเข้ากับ trend ทำให้ระดับของทั้งสองส่วนผิดไป

Seasonal indices ของ elecequip

เดือน	ม.ค.	ก.พ.	มี.ค.	เม.ย.	พ.ค.	มิ.ย.
$\hat{S}_j$	-5.89	-6.20	$+8.08$	-6.31	-4.82	$+7.98$
เดือน	**ก.ค.**	**ส.ค.**	**ก.ย.**	**ต.ค.**	**พ.ย.**	**ธ.ค.**
$\hat{S}_j$	-1.58	-16.87	$+7.30$	$+3.01$	$+3.85$	$+11.45$

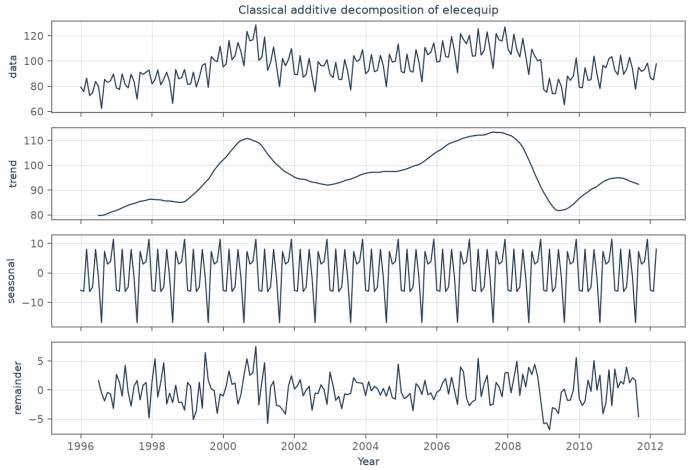
ตีความ

เดือนสิงหาคมต่ำกว่าระดับ trend อยู่ 16.87 จุด โดยเฉลี่ย ซึ่งเป็นช่วงวันหยุดฤดูร้อนของยุโรป ส่วนเดือนธันวาคมสูงกว่า trend อยู่ 11.45 จุด

ตรวจงานตัวเอง

ผลรวมของทั้ง 12 ค่าต้องเท่ากับศูนย์ ที่นี่ได้ 0.000000 พอดี

Classical additive decomposition ของ elecequip



สังเกตว่า trend รับเอา cycle ของปี 2008 ไว้ด้วย และ seasonal มีรูปร่างเดิมซ้ำทุกปีอย่างเป๊ะ ๆ

Multiplicative decomposition: เปลี่ยนลบเป็นหาร

ขั้น	Additive	Multiplicative
1	$\hat{T}_t$ จาก m-MA หรือ $2 \times m$-MA	เหมือนกันทุกประการ
2	detrended $= y_t - \hat{T}_t$	detrended $= y_t / \hat{T}_t$
3	เฉลี่ยตามหน่วยฤดูกาล แล้วปรับให้ผลรวม $= 0$	เฉลี่ยตามหน่วยฤดูกาล แล้วปรับให้ผลรวม $= m$
4	$\hat{R}_t = y_t - \hat{T}_t - \hat{S}_t$	$\hat{R}_t = y_t / (\hat{T}_t \hat{S}_t)$

ตีความต่างกันอย่างไร

additive: $\hat{S}_j = -16.87$ อ่านว่า “ต่ำกว่า trend อยู่ 16.87 หน่วย”
multiplicative: $\hat{S}_j = 0.801$ อ่านว่า “เท่ากับ 80.1% ของ trend” หรือต่ำกว่า trend อยู่ 19.9%

Seasonal indices ของ AirPassengers แบบ multiplicative

เดือน	ม.ค.	ก.พ.	มี.ค.	เม.ย.	พ.ค.	มิ.ย.
$\hat{S}_j$	0.910	0.884	1.007	0.976	0.981	1.113
เดือน	**ก.ค.**	**ส.ค.**	**ก.ย.**	**ต.ค.**	**พ.ย.**	**ธ.ค.**
$\hat{S}_j$	1.227	1.220	1.060	0.922	0.801	0.899

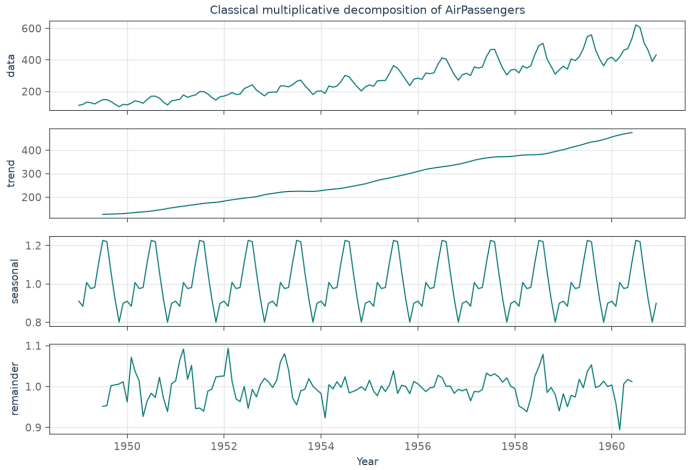
ตีความ

กรกฎาคมมีผู้โดยสารมากกว่า trend อยู่ 22.7% ส่วนพฤศจิกายนน้อยกว่า trend อยู่ 19.9% ซึ่งตรงกับฤดูกาลท่องเที่ยว

ตรวจงานตัวเอง

ผลรวมต้องเท่ากับ $m = 12$ ที่นี่ได้ 12.0000 พอดี ไม่ใช่ศูนย์เหมือนกรณี additive

Classical multiplicative decomposition ของ AirPassengers



แกนของ seasonal มีศูนย์กลางที่ 1 ไม่ใช่ 0 และ remainder ก็แกว่งรอบ 1 เช่นกัน

ทำใน Python

```python
from statsmodels.tsa.seasonal import seasonal_decompose

result = seasonal_decompose(y, model="additive", period=12)

result.trend       # T_t
result.seasonal    # S_t
result.resid       # R_t
result.observed    # y_t
result.plot()
```

- `model="multiplicative"` เปลี่ยนเป็นแบบคูณ
- `period=12` จำเป็นเมื่อ index ไม่มี frequency กำกับ
- `result.trend` จะเป็น NaN ที่ปลายทั้งสองข้าง ตามจำนวนที่ MA กินไป

ข้อจำกัดของ classical decomposition

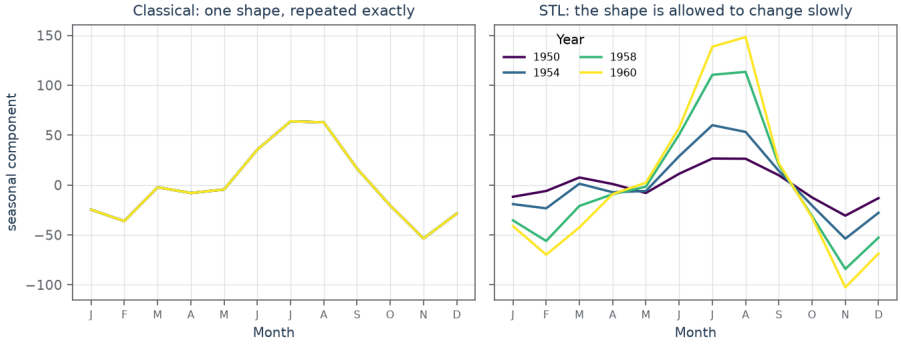
และเครื่องมือที่ยืดหยุ่นกว่า

สี่ข้อจำกัดที่ต้องรู้

ข้อจำกัด	ทำไมจึงสำคัญ
ไม่มี trend ที่ปลายอนุกรม	เสีย $m/2$ ค่าที่ปลายแต่ละข้าง ซึ่งค่าที่ปลายคือค่าที่การพยากรณ์ต้องใช้
seasonality ถูกบังคับให้คงที่	ใช้ค่าเฉลี่ยชุดเดียวตลอดทั้งอนุกรม แม้ฤดูกาลจะเปลี่ยนไปจริงในระยะยาว
ไวต่อค่าผิดปกติ	ค่าเดียวที่ผิดพลาดกระทบทั้ง MA และค่าเฉลี่ยของเดือนนั้นทุกปี
รับมือการเปลี่ยนแปลงฉับพลันไม่ได้	การกระโดดของระดับข้อมูลจะถูกเกลี่ยออกไปในหลายคาบ

ข้อจำกัดเหล่านี้ไม่ได้แปลว่า classical decomposition ใช้ไม่ได้ แต่แปลว่าเราต้องรู้ว่ามันสมมติอะไรไว้บ้าง

STL ปล่อยให้รูปร่างของฤดูกาลเปลี่ยนได้



ช่วงแกว่งของ S_t	1950	1954	1958	1960
classical	117.4	117.4	117.4	117.4
STL	57.2	113.7	197.6	250.9

STL: Seasonal and Trend decomposition using Loess

```
from statsmodels.tsa.seasonal import STL

stl = STL(y, period=12, robust=True).fit()
stl.trend, stl.seasonal, stl.resid
```

ข้อดี

- ให้ค่าครบทุกคาบ ไม่มี NaN ที่ปลาย
- seasonality เปลี่ยนได้ตามเวลา
- `robust=True` ลดอิทธิพลของค่าผิดปกติ

ข้อจำกัด

- รองรับเฉพาะ additive จึงต้องใส่ log เองถ้าข้อมูลเป็น multiplicative
- ต้องเลือกพารามิเตอร์ความเรียบเพิ่ม

วัดความแรงของ trend และ seasonality

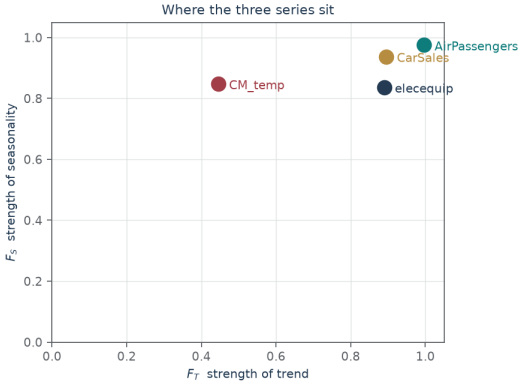
จาก $y_t = T_t + S_t + R_t$ ถ้า trend แรง ส่วนที่เหลือย่อมอธิบายความแปรปรวนได้น้อย

$$F_T = \max\left(0,\ 1 - \frac{\text{Var}(R_t)}{\text{Var}(T_t + R_t)}\right) \qquad F_S = \max\left(0,\ 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)}\right)$$

- ทั้งสองค่าอยู่ในช่วง $[0, 1]$ ยิ่งใกล้ 1 ยิ่งแรง
- ใช้ประโยชน์ได้มากเมื่อมีอนุกรมเวลาหลายร้อยชุดและต้องคัดเลือกชุดที่มีลักษณะที่ต้องการ

Wang, Smith & Hyndman (2006)

ข้อมูลสี่ชุดอยู่คนละที่บนระนาบ F_T–F_S



อนุกรมเวลา	F_T	F_S
AirPassengers	0.996	0.975
CarSales	0.895	0.937
elecequip	0.890	0.837
CM_temp	0.446	0.848

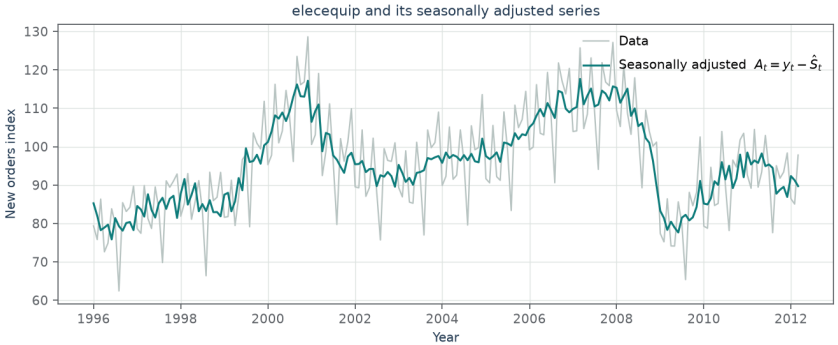
อ่านผล

CM_temp มี seasonality แรงแต่ trend อ่อน ซึ่งตรงกับสามัญสำนึก อุณหภูมิร้อนทุกเดือนเมษายน แต่ค่าเฉลี่ยรายปีแทบไม่ขยับ

การพยากรณ์และการวัดความแม่นยำ

decomposition ไม่ได้ใช้เพื่อดูอย่างเดียว แต่ใช้ทำนายได้

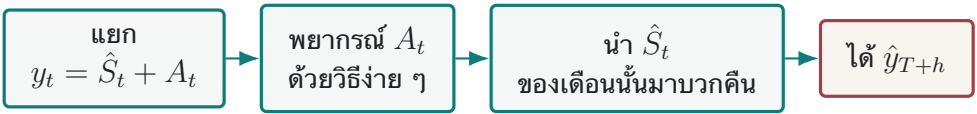
Seasonally adjusted series: ข้อมูลที่ถอดปฏิทินออกแล้ว



$$A_t = y_t - \hat{S}_t = \hat{T}_t + \hat{R}_t$$

ตัวเลขเศรษฐกิจที่รายงานว่า “ปรับฤดูกาลแล้ว” คือค่านี้ ประโยชน์คือทำให้เปรียบเทียบเดือนต่อเดือนได้โดยไม่ถูกฤดูกาลหลอก

พยากรณ์ผ่าน decomposition: แยก แล้วต่อกลับ

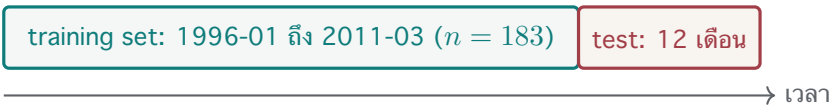


เหตุผลที่แยกก่อน

seasonality เป็นส่วนที่ทำนายง่ายที่สุด เพราะมันซ้ำเดิม เมื่อถอดออกแล้วสิ่งที่เหลือคือ trend กับ noise ซึ่งใช้วิธีง่าย ๆ พยากรณ์ได้ แล้วจึงนำฤดูกาลที่รู้อยู่แล้วมาต่อกลับ

ในคาบที่ 8 เราจะแทนขั้นตอน “พยากรณ์ A_t ด้วยวิธีง่าย ๆ” ด้วย exponential smoothing ซึ่งทำได้ดีกว่ามาก

แบ่ง training และ test ตามเวลาเท่านั้น

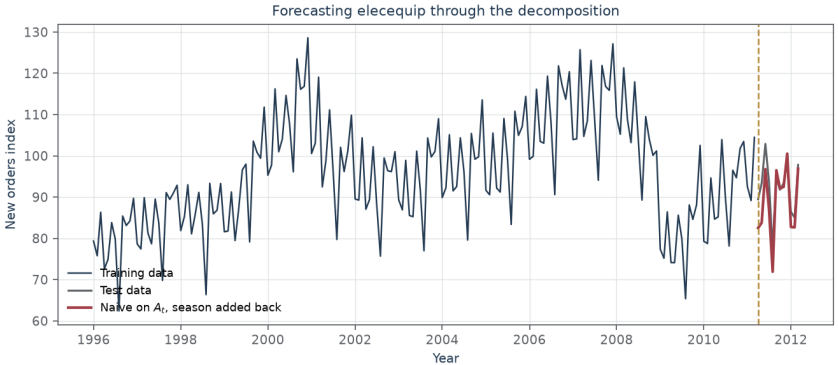


ทำไมห้ามสุ่มแบ่ง

`train_test_split(shuffle=True)` ที่ใช้ได้ดีในสัปดาห์ที่ผ่านมา จะทำให้ model เห็นข้อมูลของปี 2012 ตอนทำนายปี 2011 ค่า error ที่ได้จะต่ำอย่างสวยงามและไม่มีความหมายใด ๆ

ขนาดของ test set ควรใกล้เคียงกับ horizon ที่จะใช้พยากรณ์จริง

ผลของการพยากรณ์ผ่าน decomposition



วิธีที่ใช้

ใช้ค่า A_t ล่าสุดที่ยังมี trend กำกับเป็นค่าคงที่ตลอด horizon แล้วบวก $\hat{S}_j$ ของเดือนนั้นกลับเข้าไป ได้ RMSE เท่ากับ 4.85

สี่ benchmark ที่ทุกวิธีต้องเอาชนะให้ได้

วิธี	สูตร	เหมาะกับ
Mean	$\hat{y}_{T+h} = \bar{y}$	ข้อมูลที่แกว่งรอบค่าคงที่
Naive	$\hat{y}_{T+h} = y_T$	ข้อมูลที่เดินแบบสุ่ม เช่นราคาหุ้น
Seasonal naive	$\hat{y}_{T+h} = y_{T+h-m}$	ข้อมูลที่ seasonality เด่นมาก
Drift	$\hat{y}_{T+h} = y_T + h\frac{y_T - y_1}{T-1}$	ข้อมูลที่มี trend คงที่

ทำไมต้องมี benchmark

ตัวเลข RMSE ตัวเดียวไม่มีความหมาย จนกว่าจะมีสิ่งให้เปรียบเทียบ ถ้า model ที่ซับซ้อนแพ้ seasonal naive แปลว่าความซับซ้อนนั้นไม่ได้ให้อะไรตอบแทน

สามมาตรวัดความคลาดเคลื่อน

$$\text{RMSE} = \sqrt{\frac{1}{h}\sum e_t^2}$$

ลงโทษความผิดพลาดใหญ่หนักกว่า

หน่วยเดียวกับข้อมูล

$$\text{MAE} = \frac{1}{h}\sum |e_t|$$

ตีความง่าย ไม่ไวต่อค่าผิดปกติเท่า RMSE

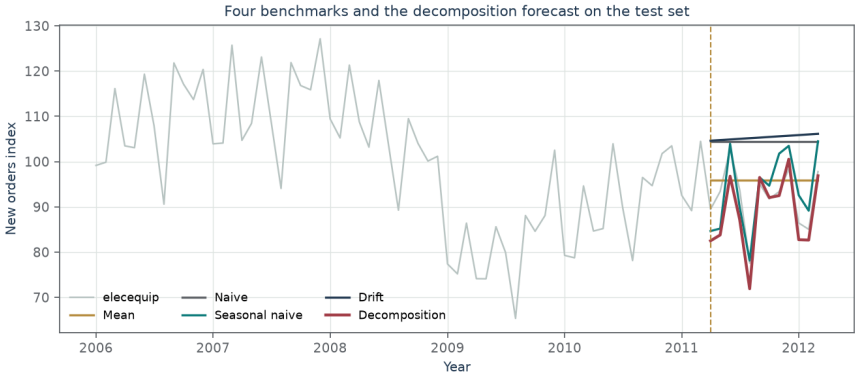
$$\text{MAPE} = \frac{100}{h}\sum \left|\frac{e_t}{y_t}\right|$$

ไม่มีหน่วย เทียบข้ามชุดข้อมูลได้

MAPE พังเมื่อไร

ถ้า y_t เป็นศูนย์หรือใกล้ศูนย์ MAPE จะระเบิดหรือหารด้วยศูนย์ และมันยังลงโทษการทำนายสูงเกินหนักกว่าการทำนายต่ำเกิน จึงห้ามใช้กับข้อมูลอย่างยอดขายรายวันที่มีวันที่ขายไม่ได้เลย

ห้าวิธีบน test set เดียวกัน



เส้นแนวนอนสองเส้นคือ Naive และ Mean ซึ่งไม่รู้จักฤดูกาลเลย ส่วนเส้นที่ขึ้นลงตามข้อมูลจริงคือ Seasonal naive และ Decomposition

ผลการเปรียบเทียบบน test set 12 เดือน

วิธี	RMSE	MAE	MAPE	ข้อสังเกต
Decomposition	4.85	3.90	4.3%	ดีที่สุด แต่ชนะไม่ขาด
Seasonal naive	5.11	4.44	4.8%	benchmark ที่แข็งมาก
Mean	7.53	5.73	6.6%	ไม่รู้จักฤดูกาล
Naive	13.99	12.41	14.1%	ยึดค่าสุดท้ายซึ่งเป็นเดือนที่ต่ำ
Drift	14.81	13.30	15.0%	ต่อ trend ผิดทิศ

สิ่งที่อ่านได้

ช่องว่างที่ใหญ่ที่สุดในตารางไม่ได้อยู่ระหว่างวิธีง่ายกับวิธียาก แต่อยู่ระหว่างวิธีที่รู้จักฤดูกาลกับวิธีที่ไม่รู้จัก การได้ seasonality มาถูกต้องมีค่ามากกว่าความซับซ้อนของ model

คำเตือน: “วิธีไหนดีที่สุด” ขึ้นกับ horizon

RMSE บน elecequip	test 12 เดือน	test 27 เดือน
Decomposition	4.85	14.59
Seasonal naive	5.11	11.76
Mean	7.53	9.07
Naive	13.99	13.24
Drift	14.81	14.76

อันดับพลิกทั้งตาราง

เมื่อยึด horizon เป็น 27 เดือน วิธีที่ชนะกลายเป็น Mean ซึ่งเป็น benchmark ที่ง่ายที่สุด เหตุผลคือ decomposition ยึดค่า A_t ค่าเดียวไว้ตลอด horizon ยิ่งทำนายไกลยิ่งผิด ขณะที่ข้อมูลหลังวิกฤตปี 2008 บังเอิญกลับมาใกล้ค่าเฉลี่ยระยะยาว

ต้องระบุ horizon เสมอเมื่อรายงานว่า model ใดดีที่สุด และต้องเลือก horizon จากการใช้งานจริง ไม่ใช่จากผลที่สวยที่สุด