Time Series 2: Exponential Smoothing

การบรรยายที่ 8: SES, Holt, Holt-Winters และ ETS

อาจารย์สิปปนนท์ กิติมูล

ภาคการศึกษาที่ 1/2569

ข้อมูลเก่ายังมีประโยชน์ แต่ไม่เท่าข้อมูลใหม่

คาบที่แล้วจบไว้ตรงไหน

สิ่งที่ทำได้แล้ว

- แยก y_t ออกเป็น T_t, S_t, R_t
- พยากรณ์ด้วย decomposition
- เทียบกับ benchmark ทั้งสี่แบบ

สิ่งที่ยังขาด

- decomposition forecast ยึด A_t ค่าเดียวไว้ตลอด horizon
- ไม่มีพารามิเตอร์ให้ปรับตามข้อมูล
- ไม่มี prediction interval

คำถามของคาบนี้

ถ้าจะให้ข้อมูลล่าสุดสำคัญกว่าข้อมูลเก่า แต่ไม่ถึงกับทิ้งข้อมูลเก่าไปทั้งหมด จะเขียนเป็นสูตรได้อย่างไร และจะหาว่า “สำคัญกว่าเท่าไร” จากข้อมูลเองได้อย่างไร

แผนที่ของคาบนี้

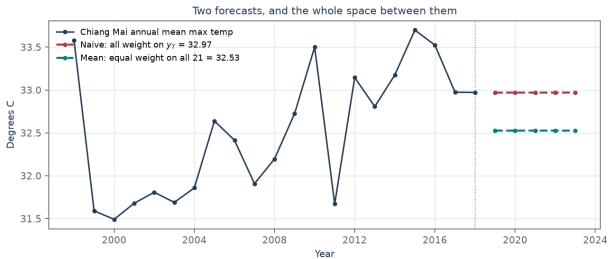


- ทุก model ในแถวนี้เป็น model เดียวกันที่ค่อย ๆ เพิ่มส่วนประกอบเข้าไป
- ปิดท้ายด้วยการเลือก model ด้วย AICc การตรวจ residual และ prediction interval

จากสองสุดขั้ว สู่ตรงกลาง

naive และ mean คือค่าเฉลี่ยถ่วงน้ำหนักคนละแบบ

สองวิธีที่ง่ายที่สุด และช่องว่างระหว่างมัน



Naive: เชื่อค่าล่าสุดค่าเดียว

$$\hat{y}_{T+1} = y_T = 32.972$$

Mean: เชื่อทุกค่าเท่ากันหมด

$$\hat{y}_{T+1} = \frac{1}{T}\sum_{t=1}^{T} y_t = 32.526$$

อุณหภูมิสูงสุดเฉลี่ยรายปีของเชียงใหม่ ปี 1998–2018 จำนวน 21 ค่า

ทั้งสองวิธีคือค่าเฉลี่ยถ่วงน้ำหนัก ต่างกันแค่น้ำหนัก

	Naive	Mean
น้ำหนักของ y_T	1	$1/T$
น้ำหนักของ y_{T-1}	0	$1/T$
น้ำหนักของ y_1	0	$1/T$
จำได้นานแค่ไหน	1 คาบ	ทั้งหมดเท่ากัน
ตอบสนองต่อการเปลี่ยนแปลง	ไวเกินไป	ช้าเกินไป

สิ่งที่ต้องการ

น้ำหนักที่ **ลดลงเรื่อย ๆ เมื่อย้อนกลับไปในอดีต** แต่ไม่ตกเป็นศูนย์ทันที ข้อมูลเมื่อวานควรสำคัญกว่าข้อมูลเมื่อปีที่แล้ว แต่ข้อมูลเมื่อปีที่แล้วก็ยังไม่ควรถูกทิ้ง

Simple exponential smoothing

model ที่มีพารามิเตอร์เดียว แต่ต้องหาด้วยการค้นหา ไม่ใช่สูตรปิด

Simple exponential smoothing (SES)

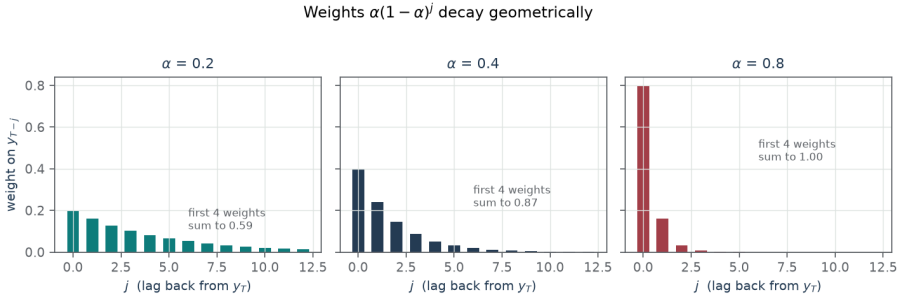
$$\hat{y}_{T+1} = \alpha y_T + \alpha(1-\alpha)y_{T-1} + \alpha(1-\alpha)^2 y_{T-2} + \cdots + \alpha(1-\alpha)^{T-1} y_1 + (1-\alpha)^T \ell_0$$

- $\alpha \in [0,1]$ คือ **smoothing parameter** ควบคุมว่าลืมเร็วแค่ไหน
- ℓ_0 คือ **initial level** ค่าตั้งต้นก่อนเห็นข้อมูลใด ๆ
- ทั้งสองค่าเป็นพารามิเตอร์ที่ต้องประมาณจากข้อมูล ไม่ใช่ค่าที่เลือกเอาเอง

สังเกต

$\alpha > \alpha(1-\alpha) > \alpha(1-\alpha)^2 > \cdots$ น้ำหนักลดลงแบบ geometric จึงเป็นที่มาของคำว่า exponential

α ควบคุมว่า model จำอดีตได้นานแค่ไหน



α	$j=0$	$j=1$	$j=2$	$j=3$	รวม 4 ค่าแรก	half-life
0.2	0.200	0.160	0.128	0.102	0.590	3.11 คาบ
0.4	0.400	0.240	0.144	0.086	0.870	1.36 คาบ
0.8	0.800	0.160	0.032	0.006	0.998	0.43 คาบ

half-life คือจำนวนคาบที่ทำให้น้ำหนักเหลือครึ่งหนึ่ง เท่ากับ $\log(0.5)/\log(1-\alpha)$

น้ำหนักรวมกันได้ 1 พอดี

ผลรวมของน้ำหนักทั้งหมด

$$\underbrace{\alpha \sum_{j=0}^{T-1} (1-\alpha)^j}_{\text{น้ำหนักของข้อมูล}} + \underbrace{(1-\alpha)^T}_{\text{น้ำหนักของ } \ell_0} = \alpha \cdot \frac{1-(1-\alpha)^T}{1-(1-\alpha)} + (1-\alpha)^T = 1$$

- จึงเป็นค่าเฉลี่ยถ่วงน้ำหนักจริง ๆ ไม่ใช่แค่ผลรวมถ่วงน้ำหนัก
- เมื่อ T โตขึ้น $(1-\alpha)^T \to 0$ อิทธิพลของ ℓ_0 จึงหายไปเอง
- แต่ถ้า T น้อยหรือ α เล็ก ℓ_0 ยังมีน้ำหนักมาก จึงต้องประมาณมันด้วย

ตัวอย่าง

$\alpha = 0.1, T = 21$: น้ำหนักที่ยังเหลืออยู่กับ ℓ_0 คือ $0.9^{21} = 0.109$ หรือราว 11%

รูปแบบเวียนเกิด: เขียนใหม่ให้คำนวณได้ทีละก้าว

กางออกทีละคาบ

$$\hat{y}_2 = \alpha y_1 + (1-\alpha)\ell_0$$

$$\hat{y}_3 = \alpha y_2 + \alpha(1-\alpha)y_1 + (1-\alpha)^2\ell_0 = \alpha y_2 + (1-\alpha)\underbrace{\left[\alpha y_1 + (1-\alpha)\ell_0\right]}_{=\hat{y}_2}$$

$$\hat{y}_4 = \alpha y_3 + (1-\alpha)\hat{y}_3$$

รูปแบบเวียนเกิดของ SES

$$\hat{y}_{t+1} = \alpha y_t + (1-\alpha)\hat{y}_t$$

ค่าพยากรณ์ใหม่ = ค่าจริงล่าสุด ผสมกับ ค่าพยากรณ์เดิม ในสัดส่วน α ต่อ $1-\alpha$ สองรูปแบบนี้เป็น model เดียวกัน รูปแรกบอกว่าน้ำหนักหน้าตาเป็นอย่างไร รูปที่สองใช้คำนวณจริงเพราะเก็บแค่ค่าเดียวก็พอ

รูปแบบส่วนประกอบ: แยก “ระดับ” ออกมาเป็นตัวแปร

Component form

$$\begin{aligned} \text{Forecast equation} \quad & \hat{y}_{t+h|t} = \ell_t \\ \text{Level equation} \quad & \ell_t = \alpha y_t + (1-\alpha)\ell_{t-1} \end{aligned}$$

- ℓ_t คือ **level** หรือระดับของอนุกรม ณ เวลา t หลังกรอง noise ออกแล้ว
- $\hat{y}_{t+h|t} = \ell_t$ **ทุกค่าของ** h ค่าพยากรณ์จึงเป็นเส้นแนวนอน
- รูปแบบนี้สำคัญ เพราะ Holt และ Holt-Winters จะเพิ่มสมการเข้ามาในรูปแบบเดียวกันนี้

อ่านสมการ level ให้เป็น

ℓ_t คือค่าเฉลี่ยถ่วงน้ำหนักระหว่าง สิ่งที่เพิ่งเห็น (y_t) กับ สิ่งที่เคยเชื่อ (ℓ_{t-1}) ทุกสมการที่เหลือในคาบนี้อ่านแบบเดียวกันหมด

การหาพารามิเตอร์: ทำไมจึงไม่ใช่ least squares แบบเดิม

เกณฑ์ที่ใช้คือ SSE เหมือนเดิม

$$\text{SSE}(\alpha, \ell_0) = \sum_{t=1}^{T} \big(y_t - \hat{y}_{t|t-1}\big)^2$$

Linear regression

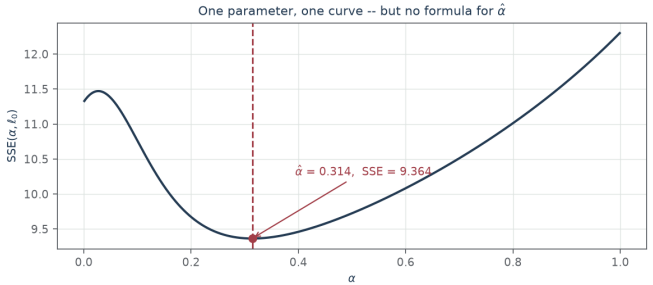
- $\hat{y}$ เป็นเชิงเส้นใน β
- มีสูตรปิด $\hat{\boldsymbol{\beta}} = (X^\top X)^{-1} X^\top \boldsymbol{y}$

SES

- $\hat{y}$ มี $\alpha, \alpha^2, \ldots, \alpha^T$ อยู่ด้วย
- ไม่เป็นเชิงเส้นใน α จึงไม่มีสูตรปิด
- ต้องใช้การค้นหาเชิงตัวเลข

แต่ถ้า ตรึง α ไว้ SSE จะเป็นฟังก์ชันกำลังสองใน ℓ_0 จึงหา ℓ_0 ที่ดีที่สุดได้ด้วยสูตรปิด นี่คือวิธีที่ใช้วาดกราฟหน้าถัดไป

หน้าตาของ SSE เมื่อ α เปลี่ยน



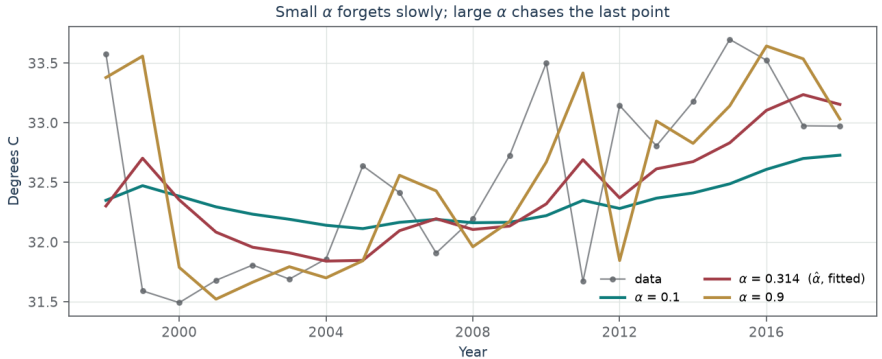
α	SSE
0.05	11.376
0.314	9.364
0.95	11.938

ผลลัพธ์

$\hat{\alpha} = 0.314$, $\hat{\ell}_0 = 32.303$, SSE $= 9.364$

ทุกจุดบนเส้นโค้งนี้ ค่า ℓ_0 ถูกหาใหม่ให้ดีที่สุดสำหรับ α นั้น ไม่ได้ตรึงไว้ที่ค่าเดียว

α เล็กกับ α ใหญ่ ต่างกันอย่างไรบนข้อมูลชุดเดียวกัน



- $\alpha = 0.1$ เส้นเรียบมาก แทบไม่ตอบสนองต่อปีที่ผิดปกติ
- $\alpha = 0.9$ เส้นวิ่งตามข้อมูลเกือบทุกจุด แทบเป็น naive forecast ที่ช้าไปหนึ่งก้าว
- $\hat{\alpha} = 0.314$ อยู่ตรงกลาง และเป็นค่าที่ข้อมูลเลือกเอง ไม่ใช่ที่เราเลือก

การคำนวณจริง ทีละแถว

t	ปี	y_t	$\hat{y}_{t\|t-1}$	ℓ_t
0				32.303
1	1998	33.579	32.303	32.704
2	1999	31.591	32.704	32.354
3	2000	31.493	32.354	32.083
4	2001	31.680	32.083	31.957
5	2002	31.808	31.957	31.910
		⋮		
21	2018	32.972	33.154	33.097

แถวแรก

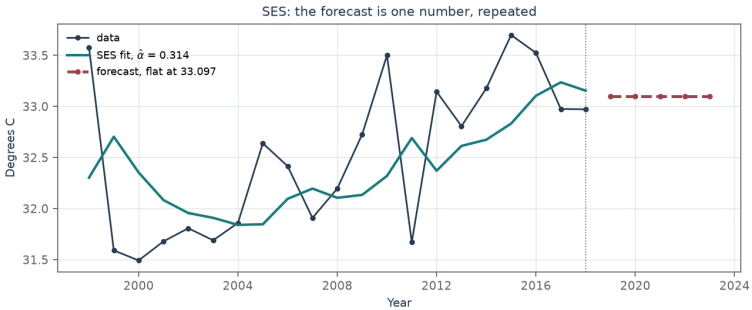
$\hat{y}_{1|0} = \ell_0$ พอดี เพราะยังไม่เห็นข้อมูลใด ๆ

$$\ell_1 = 0.314 \times 33.579 + 0.686 \times 32.303$$
$$= 32.704$$

แถวสุดท้าย

$\ell_{21} = 33.097$ คือค่าพยากรณ์สำหรับ ทุกปีข้างหน้า

ค่าพยากรณ์ของ SES เป็นเส้นแนวนอน



ทำไมจึงแบน

$\hat{y}_{T+h|T} = \ell_T$ ไม่ขึ้นกับ h เลย SES ไม่มีส่วนประกอบใดที่บอกทิศทาง จึงพยากรณ์ว่าอนาคตจะอยู่ที่ระดับปัจจุบันตลอดไป ถ้าข้อมูลมี trend ชัดเจน ข้อจำกัดนี้จะเสียหายทันที และเป็นเหตุผลที่ต้องมี Holt

Holt: เพิ่ม trend เข้าไป

ระดับอย่างเดียวไม่พอเมื่อข้อมูลไต่ขึ้นทุกปี

Holt's linear trend method

สามสมการ

$$
\begin{aligned}
\text{Forecast} \quad & \hat{y}_{t+h|t} = \ell_t + h\, b_t \\
\text{Level} \quad & \ell_t = \alpha y_t + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\
\text{Trend} \quad & b_t = \beta(\ell_t - \ell_{t-1}) + (1-\beta) b_{t-1}
\end{aligned}
$$

- ℓ_t คือระดับ และ b_t คือ **ความชัน** ต่อหนึ่งคาบ
- พารามิเตอร์เพิ่มเป็นสี่ตัว: α, β, ℓ_0, b_0
- ค่าพยากรณ์เป็นฟังก์ชันเชิงเส้นของ h ไม่ใช่เส้นแนวนอนอีกต่อไป

อ่านสองสมการนี้ให้เป็น

Level

$$\ell_t = \alpha \underbrace{y_t}_{\text{เพิ่งเห็น}} + (1-\alpha) \underbrace{(\ell_{t-1} + b_{t-1})}_{\text{ที่เคยทำนายไว้}}$$

- $\ell_{t-1} + b_{t-1}$ คือระดับที่ควรจะเป็นถ้า trend เดิมยังจริง
- เฉลี่ยกับค่าที่สังเกตได้จริง

Trend

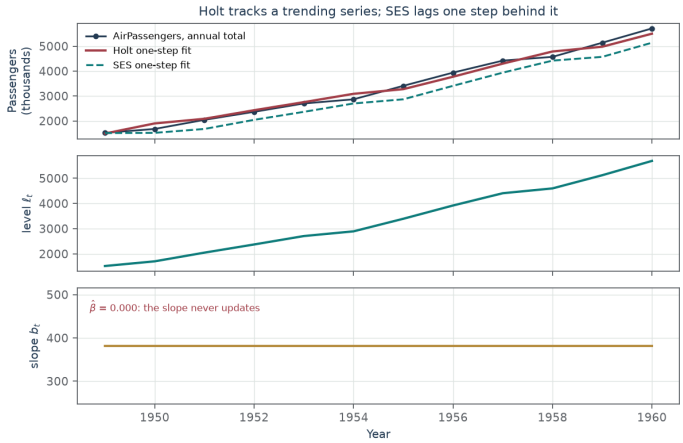
$$b_t = \beta \underbrace{(\ell_t - \ell_{t-1})}_{\text{ความชันที่เพิ่งวัดได้}} + (1-\beta) \underbrace{b_{t-1}}_{\text{ความชันเดิม}}$$

- ความชันใหม่คือส่วนต่างของระดับสองคาบล่าสุด
- เฉลี่ยกับความชันที่เชื่ออยู่ก่อน

รูปแบบเดียวกันทั้งคาบ

ทุกสมการมีหน้าตา (ค่าใหม่ที่วัดได้) $\times$ พารามิเตอร์ $+$ (ค่าเดิมที่เชื่ออยู่) $\times$ ส่วนที่เหลือ ถ้าอ่านแบบนี้ได้ Holt-Winters จะไม่มีอะไรใหม่เลยนอกจากสมการที่สาม

ระดับและความชันบนข้อมูลที่มี trend จริง



AirPassengers รวมรายปี 1949–1960 SES ตามหลังอยู่หนึ่งก้าวเสมอ เพราะไม่มีตัวแปรใดเก็บทิศทางไว้

$\hat{\beta} = 0$ หมายความว่าอย่างไร

ผลที่ได้จากการ fit

บนข้อมูลชุดนี้ $\hat{\alpha} = 0.881$ แต่ $\hat{\beta} = 0.000$ และ $\hat{b}_0 = 381.44$

- $\beta = 0$ ทำให้ $b_t = b_{t-1} = \cdots = b_0$ ความชัน **ไม่เคยถูกปรับ** เลยตลอดอนุกรม
- Holt ในกรณีนี้จึงกลายเป็นเส้นตรงที่ความชันคงที่ ซึ่งก็คือเส้นตรงกำลังสองน้อยสุดบนดัชนีเวลา
- นี่คือเส้นเดียวกับที่คาบที่ 7 เปิดเรื่องด้วยและบอกว่าใช้ไม่ได้ ต่างกันที่คราวนี้ ข้อมูลเป็นคนเลือกเอง

บทเรียนเรื่องการอ่านผล

ค่าพารามิเตอร์ที่ชนขอบ 0 หรือ 1 ไม่ใช่ error แต่เป็นข้อความที่ข้อมูลกำลังบอกว่าส่วนประกอบนั้นไม่ต้องขยับ ต้องอ่านมันเสมอ อย่าดูแค่ค่าพยากรณ์

แล้ว trend คุ้มกับพารามิเตอร์ที่เพิ่มมาหรือไม่

อุณหภูมิเชียงใหม่รายปี	SSE	AIC	AICc	BIC
SES (A, N, N)	9.364	48.64	50.05	51.77
Holt (A, A, N)	7.276	47.34	51.34	52.56
Damped Holt (A, A_d, N)	7.447	49.82	55.82	56.09

SSE ต่ำสุดไม่ได้ชนะ

Holt ลด SSE ลงได้จริงจาก 9.364 เหลือ 7.276 แต่ต้องจ่ายด้วยพารามิเตอร์เพิ่มอีกสองตัว AICc จึงยังเลือก SES

เทียบกับอีกชุด

บน AirPassengers รายปี Holt ชนะ AICc ที่ 174.94 ต่อ 186.63 ที่นั่น trend คุ้ม ที่นี่ไม่คุ้ม

อุณหภูมิเชียงใหม่ไต่ขึ้นราว $0.07°$C ต่อปี ซึ่งเป็น trend ที่มีอยู่จริง แต่เล็กเกินกว่าที่ข้อมูล 21 ปีจะยืนยันได้

Damped Holt: ใส่เบรกให้ trend

เส้นตรงที่ยิงไปไม่สิ้นสุดแทบไม่เคยสมจริง

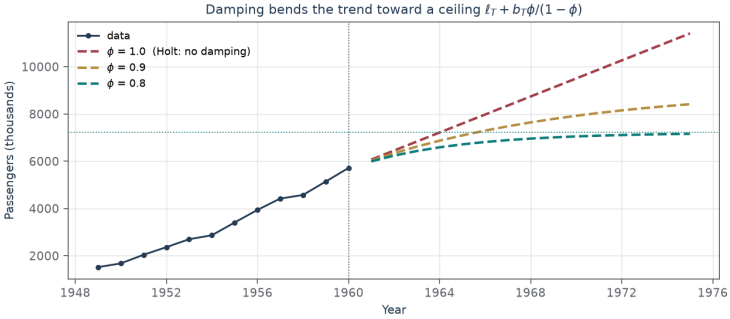
ปัญหาของ trend เชิงเส้น

- Holt พยากรณ์ว่าความชันเดิมจะอยู่ต่อไป **ตลอดกาล**
- ยิ่ง horizon ไกล ยิ่งเป็นข้ออ้างที่รับไม่ได้ เช่น โรงงานที่มีเครื่องจักรจำนวนคงที่ย่อมผลิตเพิ่มไม่จำกัดไม่ได้
- งานเชิงประจักษ์พบว่า damped trend พยากรณ์ได้ดีกว่าอย่างสม่ำเสมอในระยะกลางถึงยาว

Damped Holt (Gardner & McKenzie, 1985) กำหนด $0 \leq \phi \leq 1$

$$\begin{aligned}
\hat{y}_{t+h|t} &= \ell_t + (\phi + \phi^2 + \cdots + \phi^h) b_t \\
\ell_t &= \alpha y_t + (1-\alpha)(\ell_{t-1} + \phi b_{t-1}) \\
b_t &= \beta(\ell_t - \ell_{t-1}) + (1-\beta)\phi b_{t-1}
\end{aligned}$$

ϕ ทำอะไรกับค่าพยากรณ์



h	$\phi = 1.0$	$\phi = 0.9$	$\phi = 0.8$
1	6070.2	6032.0	5993.9
5	7595.9	7094.6	6714.5
15	11410.4	8414.9	7160.8
เพดาน $h \to \infty$	ไม่มี	9121.7	7214.5

อ่านค่า ϕ

$\phi = 1$

กลับไปเป็น Holt เดิม ไม่มีการหน่วง

$\phi = 0$

trend หายไปทั้งหมด เหลือค่าคงที่ เท่ากับ SES

ในทางปฏิบัติ

$0.8 \leq \phi \leq 0.98$ ต่ำกว่านี้แทบไม่ต่างจากทิ้ง trend

เพดานของค่าพยากรณ์

เมื่อ $h \to \infty$ ผลรวม $\phi + \phi^2 + \cdots \to \dfrac{\phi}{1-\phi}$ ค่าพยากรณ์จึงลู่เข้าสู่

$$\ell_T + b_T \frac{\phi}{1-\phi}$$

เป็นเส้นแนวนอน แต่อยู่สูงกว่าระดับปัจจุบัน ต่างจาก SES ที่แบนอยู่ที่ระดับปัจจุบันพอดี

Holt-Winters: เพิ่ม seasonality

สมการที่สาม และเลขดัชนีที่ต้องนับให้ถูก

Holt-Winters additive method

สี่สมการ

$$
\begin{aligned}
\hat{y}_{t+h|t} &= \ell_t + hb_t + s_{t+h-m(k+1)} \\
\ell_t &= \alpha(y_t - s_{t-m}) + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\
b_t &= \beta(\ell_t - \ell_{t-1}) + (1-\beta)b_{t-1} \\
s_t &= \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1-\gamma)s_{t-m}
\end{aligned}
$$

- m คือคาบของฤดูกาล เช่น $m = 12$ สำหรับข้อมูลรายเดือน
- ℓ_t เฉลี่ยระหว่าง **ค่าที่ถอด seasonality ออกแล้ว** $y_t - s_{t-m}$ กับ $\ell_{t-1} + b_{t-1}$
- s_t เฉลี่ยระหว่าง **ค่าที่ถอด level และ trend ออกแล้ว** กับดัชนีฤดูกาลของคาบก่อน

ดัชนีฤดูกาลตัวไหนถูกหยิบมาใช้

ข้อมูลจบที่ $t = 2019\text{-}01$



$h = 2 \Rightarrow$ ทำนาย 2019-03 แต่ใช้ดัชนีของ 2018-03

h	เดือนที่ทำนาย	ดัชนีที่ใช้
1	2019-02	2018-02
2	2019-03	2018-03
12	2020-01	2019-01
13	2020-02	2018-02 (ซ้ำกับ $h = 1$)

มีดัชนีฤดูกาลอยู่แค่ m ค่าล่าสุดเท่านั้น เมื่อ $h > m$ จึงต้องวนกลับมาใช้ค่าเดิมซ้ำ

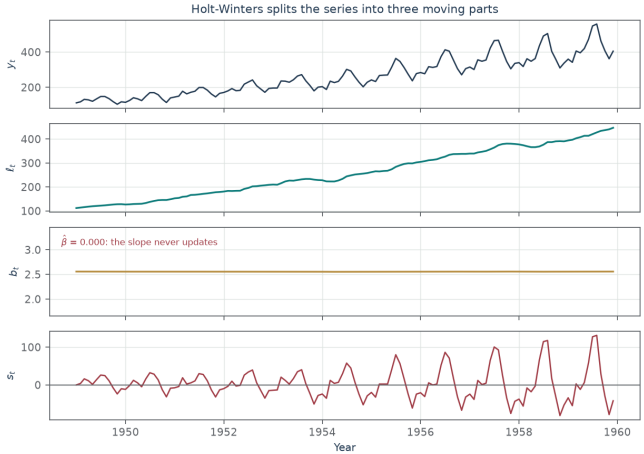
พารามิเตอร์เพิ่มขึ้นเร็วมาก

Method	Smoothing	ค่าตั้งต้น	รวม
SES	α	ℓ_0	2
Holt	α, β	ℓ_0, b_0	4
Damped Holt	α, β, ϕ	ℓ_0, b_0	5
Holt-Winters ($m = 12$)	α, β, γ	$\ell_0, b_0, s_{-11}, \ldots, s_0$	17

ผลที่ตามมา

ข้อมูลรายเดือน 3 ปีมี 36 จุด แต่ Holt-Winters ต้องประมาณ 17 ค่า การเลือก model ด้วย SSE เพียงอย่างเดียวจึงเชื่อไม่ได้ ต้องมีบทลงโทษตามจำนวนพารามิเตอร์ ซึ่งเป็นเหตุผลที่หัวข้อถัดไปคือ AICc

ส่วนประกอบทั้งสามบน AirPassengers



$\hat{\alpha} = 0.251$, $\hat{\beta} = 0.000$, $\hat{\gamma} = 0.749$ ระดับขยับตามข้อมูล ฤดูกาลปรับตัวเร็ว แต่ความชันถูกตรึงไว้อีกครั้ง

Holt-Winters multiplicative

กฎการแปลง

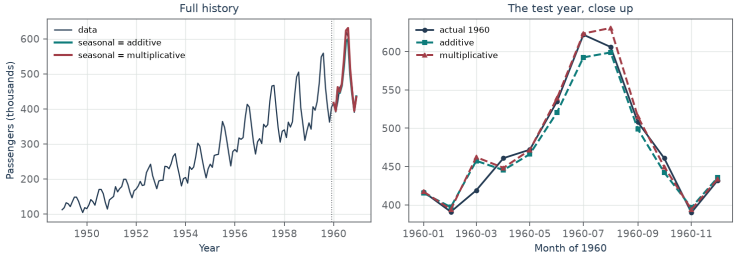
บวกด้วย $s_t \longrightarrow$ คูณด้วย s_t, ลบด้วย $s_t \longrightarrow$ หารด้วย s_t

สมการ

$$
\begin{aligned}
\hat{y}_{t+h|t} &= (\ell_t + hb_t)\, s_{t+h-m(k+1)} \\
\ell_t &= \alpha \tfrac{y_t}{s_{t-m}} + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\
b_t &= \beta(\ell_t - \ell_{t-1}) + (1-\beta) b_{t-1} \\
s_t &= \gamma \tfrac{y_t}{\ell_{t-1} + b_{t-1}} + (1-\gamma) s_{t-m}
\end{aligned}
$$

แบบ additive ดัชนีฤดูกาลมีหน่วยเดียวกับข้อมูล แบบ multiplicative ดัชนีเป็นสัดส่วนรอบ ๆ 1

เลือกแบบไหน: กลับไปที่คำถามเชิงหลักฐานของคาบที่ 7



seasonal	AICc	RMSE
additive	1064.30	16.87
multiplicative	1019.31	15.46

ตรงกับหลักฐานเชิงโครงสร้าง

คาบที่ 7 วัด Cor(ระดับรายปี, ช่วงแกว่งรายปี) ของ AirPassengers ได้ $+0.991$ ซึ่งเป็นลายเซ็นของ multiplicative ที่ชัดที่สุดในสี่ชุดข้อมูล

train 1949–1959 test 12 เดือนของปี 1960 ทั้ง AICc และ RMSE บนข้อมูลที่กันไว้เห็นตรงกัน ซึ่งไม่ได้เกิดขึ้นเสมอไป

ETS: กรอบที่รวมทุก model ข้างต้น

Error, Trend, Seasonal และการเลือกด้วย AICc

สาม slot สามตัวเลือก

Slot	ตัวเลือก	ความหมาย
Error E	A, M	ความคลาดเคลื่อนบวกเข้าไป หรือคูณตามขนาดของข้อมูล
Trend T	N, A, A_d, M, M_d	ไม่มี, เชิงเส้น, เชิงเส้นแบบหน่วง, และแบบคูณอีกสองแบบ
Seasonal S	N, A, M	ไม่มี, บวก, คูณ

จำนวน model

$2 \times 5 \times 3 = 30$ แบบ

ที่ใช้จริง

แบบที่มี M ใน trend ไม่เสถียรและแทบไม่ใช้ ในทางปฏิบัติจึงเหลือราว 18 แบบ

ทุก method ในคาบนี้เป็นสมาชิกของตารางเดียวกัน

ETS	ชื่อที่เรียกกัน	ค่าพยากรณ์ระยะยาว
(A, N, N)	Simple exponential smoothing	เส้นแนวนอนที่ ℓ_T
(A, A, N)	Holt's linear trend	เส้นตรงชัน b_T
(A, A_d, N)	Damped Holt	เส้นแนวนอนที่ $\ell_T + b_T\phi/(1-\phi)$
(A, A, A)	Holt-Winters additive	เส้นตรง บวกฤดูกาลคงที่
(A, A, M) หรือ (M, A, M)	Holt-Winters multiplicative	เส้นตรง คูณฤดูกาล

ประโยชน์ของกรอบนี้

ไม่ต้องจำสูตรทีละ method แต่ให้ถามสามคำถามแทน: ข้อมูลมี trend ไหม มี seasonality ไหม และความผันผวนโตตามระดับหรือไม่ คำตอบสามข้อระบุ model ได้ทันที

ทั้งสามตัวมีหน้าตาเดียวกัน

$$\text{AIC} = -2\log L + 2k, \qquad \text{AICc} = \text{AIC} + \frac{2k(k+1)}{T-k-1}, \qquad \text{BIC} = -2\log L + k\log T$$

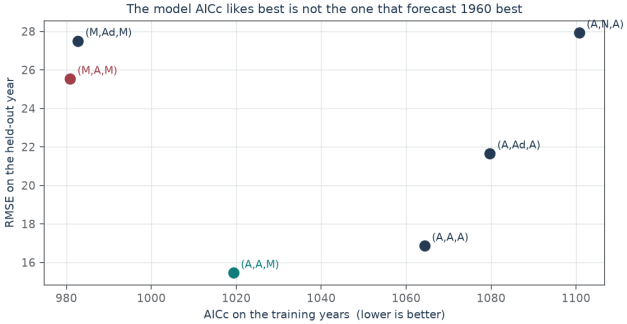
โดย k คือจำนวนพารามิเตอร์ทั้งหมด รวมค่าตั้งต้นและความแปรปรวน

- ใช้ AICc เป็นหลักสำหรับอนุกรมเวลา เพราะ T มักเล็กเมื่อเทียบกับ k
- เทียบได้เฉพาะ model ที่ fit บนข้อมูลชุดเดียวกันและตัวแปรตามเดียวกัน
- ค่าต่างกันน้อยกว่าราว 2 ถือว่าแยกไม่ออก อย่าตัดสินจากทศนิยม

ข้อควรระวังเรื่อง M ใน error

model ที่ error เป็นแบบคูณมี likelihood คนละสเกลกับแบบบวกในบางการนำไปใช้ ให้เทียบภายในชุดที่ library เดียวกันคำนวณให้เท่านั้น

AICc กับ RMSE บนข้อมูลที่กันไว้ ไม่ได้เห็นตรงกันเสมอ



ETS	AICc	RMSE ปี 1960	
(M, A, M)	980.83	25.53	AICc เลือกตัวนี้
(A, A, M)	1019.31	15.46	แต่ตัวนี้ทำนายดีกว่ามาก
(A, A, A)	1064.30	16.87	
(A, N, A)	1100.72	27.94	

ทำไมจึงไม่ตรงกัน และควรทำอย่างไร

AICc วัดอะไร

ความพอดีกับข้อมูล ที่ใช้ fit หลังหักบทลงโทษตามจำนวนพารามิเตอร์ เป็นการประมาณความสามารถในการทำนายแบบหนึ่งก้าว

RMSE บน test วัดอะไร

ความแม่นยำบนข้อมูลที่ model ไม่เคยเห็น ที่ horizon ซึ่งเราสนใจจริง ๆ ในที่นี้คือ 12 เดือน

ข้อสรุปที่ใช้ได้

- ถ้าเป้าหมายคือพยากรณ์ที่ horizon หนึ่ง ๆ ให้ตัดสินด้วย **test set ที่ horizon นั้น** เสมอ
- ใช้ AICc เมื่อข้อมูลสั้นเกินกว่าจะกันบางส่วนไว้ได้ หรือใช้เพื่อคัดตัวเลือกให้แคบลงก่อน
- รายงานทั้งสองค่า และระบุ horizon ที่ใช้ทดสอบ เหมือนที่คาบที่ 7 ทำกับตาราง benchmark

Residual และความไม่แน่นอน

ค่าพยากรณ์จุดเดียวไม่พอสำหรับการตัดสินใจ

Innovation residuals

นิยาม

$$e_t = y_t - \hat{y}_{t|t-1}$$

ความคลาดเคลื่อนของการทำนายหนึ่งก้าว โดยใช้ข้อมูลถึงเวลา $t-1$ เท่านั้น

คุณสมบัติที่จำเป็น

- ค่าเฉลี่ยใกล้ศูนย์ ไม่เช่นนั้น model มี bias
- ไม่มี autocorrelation เหลืออยู่

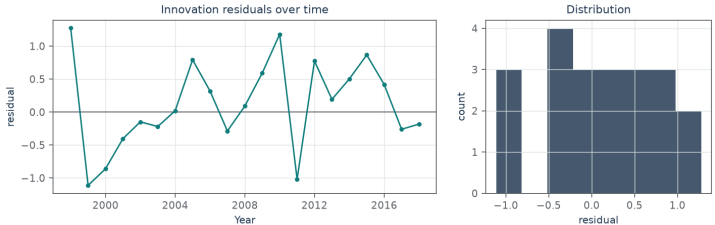
คุณสมบัติที่อยากได้

- ความแปรปรวนคงที่
- แจกแจงใกล้เคียงปกติ

จำเป็นสำหรับ prediction interval แต่ไม่จำเป็นสำหรับค่าพยากรณ์จุด

ถ้ายังมี autocorrelation เหลืออยู่ แปลว่ายังมีข้อมูลที่ใช้ทำนายได้แต่ model ยังไม่ได้ใช้

ตรวจ residual ของ SES บนข้อมูลเชียงใหม่



lag	Q	p
5	0.362	0.9963
10	2.007	0.9963

ค่าเฉลี่ย $+0.120$, ส่วนเบี่ยงเบน 0.673

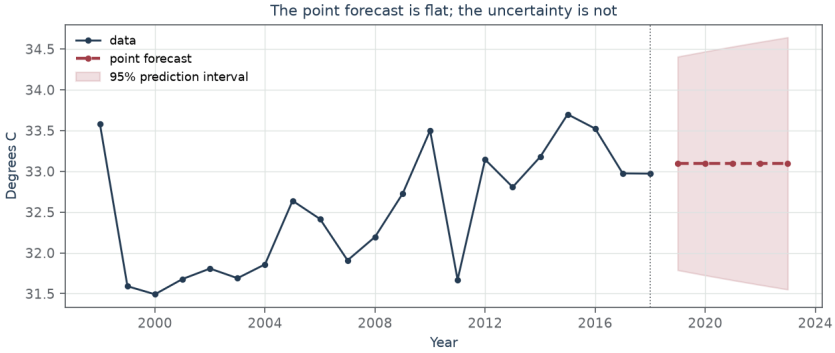
Ljung-Box test

H_0: ไม่มี autocorrelation ในกลุ่ม lag แรก ๆ ค่า p สูงมากจึง **ไม่ปฏิเสธ** H_0

อ่านให้ถูก

p สูงไม่ได้พิสูจน์ว่า model ถูก แปลเพียงว่าการทดสอบนี้ไม่พบสิ่งผิดปกติ

Prediction interval



h	ปี	ค่าพยากรณ์	ช่วง 95%	ความกว้าง
1	2019	33.097	$[31.788,\ 34.406]$	2.618
3	2021	33.097	$[31.665,\ 34.529]$	2.864
5	2023	33.097	$[31.551,\ 34.643]$	3.092

ทำไมช่วงจึงกว้างขึ้นช้ามาก

สำหรับ SES ความแปรปรวนของความคลาดเคลื่อน h ก้าวคือ

$$\text{Var}(y_{T+h} - \hat{y}_{T+h|T}) = \sigma^2\left[1 + (h-1)\alpha^2\right]$$

- $\hat{\sigma} = 0.668$ และ $\hat{\alpha} = 0.314$ ดังนั้น $\alpha^2 = 0.099$ ซึ่งเล็กมาก
- ช่วงจึงกว้างขึ้นจาก 2.618 เป็น 3.092 เมื่อทำนายไกลออกไป 5 ปี เพิ่มขึ้นเพียง 18%
- ตรงข้ามกับ random walk ที่ความแปรปรวนโตเป็น $h\sigma^2$ ซึ่งจะพบในคาบที่ 9

ข้อควรระวัง

ช่วงนี้คำนวณโดยสมมติว่าพารามิเตอร์ที่ประมาณได้ถูกต้องแน่นอน ความไม่แน่นอนของ $\hat{\alpha}$ เองไม่ถูกนับรวม ช่วงจริงจึงกว้างกว่าที่แสดงเสมอ

ลงมือทำใน Python

API ที่ต้องใช้ และกับดักที่ต้องเลี่ยง

ETSModel คือ API ที่ควรใช้

```python
from statsmodels.tsa.exponential_smoothing.ets import ETSModel

y = df["MaxTemp"].asfreq("YS")     # a DatetimeIndex with a frequency

fit = ETSModel(y, error="add", trend="add", damped_trend=True,
               seasonal="add", seasonal_periods=12).fit(disp=False)

print(fit.smoothing_level, fit.smoothing_trend, fit.smoothing_seasonal)
print(fit.aicc, fit.sse)
print(fit.states.head())           # level / trend / seasonal paths

point = fit.forecast(12)
band = fit.get_prediction(start=len(y), end=len(y) + 11)
band.summary_frame(alpha=0.05)     # mean, pi_lower, pi_upper
```

`trend=None` และ `seasonal=None` คือการปิด slot นั้น ไม่ใช่ `"none"`

กับดักที่เสียเวลามากที่สุด

สิ่งที่พบ	สิ่งที่ต้องทำ
`holtwinters` ไม่มี `get_prediction`	ใช้ `ETSModel` ถ้าต้องการ prediction interval คลาสเดิมทำไม่ได้เลย
AICc ของสอง API ไม่เท่ากัน	fit เดียวกันได้ 50.05 จาก `ets` แต่ -10.46 จาก `holtwinters` **ห้ามเทียบข้าม API**
`damped=True`	เปลี่ยนชื่อเป็น `damped_trend=True` แล้ว
`resample("M")`	pandas 3 ใช้ `"ME"` หรือ `"MS"`
ไม่ได้ตั้ง frequency ของ index	`seasonal_periods` จะตีความผิด ให้ `asfreq` ก่อนเสมอ

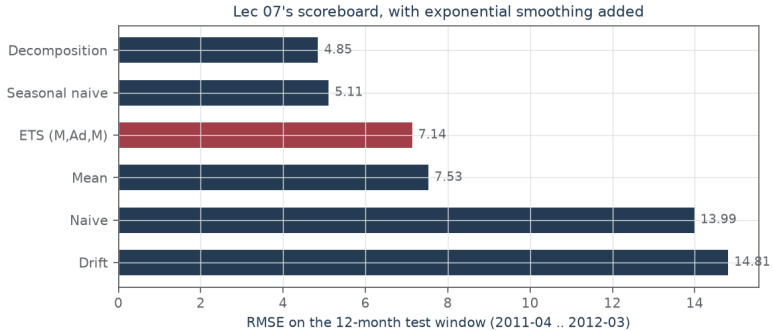
เรื่อง AICc ข้าม API

ตัวเลขทั้งสองไม่ผิด แต่มาจากนิยาม likelihood คนละแบบ ถ้าเผลอเทียบข้ามกันจะสรุปกลับด้านได้ทั้งตาราง สไลด์ทุกหน้าในคาบนี้ใช้ `ETSModel` อย่างเดียว

กลับไปที่ตารางคะแนนของคาบที่ 7

model ที่ซับซ้อนกว่าไม่ได้แปลว่าดีกว่า

เพิ่ม ETS ลงในตารางเดิม บนข้อมูลและช่วงทดสอบเดิม



เงื่อนไขเดียวกันทุกอย่าง

elecequip, train ถึง 2011-03, test 12 เดือน 2011-04 ถึง 2012-03 เป็นช่วงเดียวกับที่คาบที่ 7 ใช้

อ่านผลนี้อย่างซื่อสัตย์

วิธี	RMSE	หมายเหตุ
Decomposition	4.85	จากคาบที่ 7
Seasonal naive	5.11	benchmark ที่ไม่มีพารามิเตอร์เลย
ETS (M, A_d, M)	7.14	AICc ดีที่สุดในหกแบบที่ลอง
Mean	7.53	
Naive	13.99	

ETS แพ้ทั้ง decomposition และ seasonal naive บนชุดนี้

และซ้ำร้าย ETS ตัวที่ AICc เลือก (M, A_d, M) ทำ RMSE ได้ 7.14 ขณะที่ (A, N, A) ซึ่ง AICc ให้อันดับแย่กว่า ทำได้ 5.57 เป็นรูปแบบเดียวกับที่เห็นบน AirPassengers

elecequip มี cycle จากวิกฤตปี 2008 ซึ่ง exponential smoothing ไม่มีส่วนประกอบใดรองรับ ส่วน decomposition ได้เปรียบเพราะ seasonally adjusted series ดูดซับมันไปไว้ใน trend

สรุปคาบที่ 8

1. exponential smoothing ให้น้ำหนักลดลงแบบ geometric กับข้อมูลที่เก่าลง โดยมี α เป็นตัวควบคุม
2. SES มีสมการเดียวคือ level และพยากรณ์เป็นเส้นแนวนอน
3. Holt เพิ่มสมการ trend ทำให้พยากรณ์เป็นเส้นตรง damped Holt ใส่ ϕ เพื่อให้ trend ลู่เข้าเพดาน
4. Holt-Winters เพิ่มสมการ seasonal และมีทั้งแบบบวกและแบบคูณ เลือกจากหลักฐานว่าช่วงแกว่งโตตามระดับหรือไม่
5. ETS รวมทั้งหมดเป็นตารางเดียว ระบุด้วยสามตัวอักษร (E, T, S)
6. พารามิเตอร์หาโดยการค้นหาเชิงตัวเลขบน SSE หรือ likelihood ไม่มีสูตรปิด
7. เลือก model ด้วย AICc ได้ แต่ต้องยืนยันด้วย test set ที่ horizon ที่ใช้งานจริง
8. ตรวจ residual และรายงาน prediction interval เสมอ ค่าพยากรณ์จุดเดียวไม่พอ

คาบที่ 9

Stationarity, differencing, ACF และ PACF นำไปสู่ ARIMA และการเทียบกับ ETS

อ่านเพิ่มเติม

Hyndman & Athanasopoulos, Forecasting: Principles and Practice, 2nd ed.

- §7.1 simple exponential smoothing
- §7.2 Holt และ damped Holt
- §7.3 Holt-Winters ทั้งสองแบบ
- §7.4 ตาราง ETS taxonomy
- §7.6 การประมาณพารามิเตอร์และการเลือก model ด้วย AICc
- §7.7 การพยากรณ์และ prediction interval จาก ETS

ฉบับที่ 3 ย้ายเนื้อหาบทที่ 7 ทั้งหมดไปเป็นบทที่ 8 โดยหัวข้อย่อยเรียงเหมือนเดิม ตำราทั้งสองฉบับอ่านฟรีที่ `otexts.com`