Time Series 3: Stationarity และ ARIMA

การบรรยายที่ 9: differencing, ACF/PACF, ARIMA/SARIMA และการเลือกโมเดล

อาจารย์สิปปนนท์ กิติมูล

ภาคการศึกษาที่ 1/2569

ถ้าข้อมูลเปลี่ยนพฤติกรรมไปเรื่อย ๆ ก็ไม่มีอะไรให้เรียนรู้ ขั้นแรกคือทำให้มันหยุดเปลี่ยน

สองคาบที่ผ่านมาจบไว้ตรงไหน

สิ่งที่ทำได้แล้ว

- แยก y_t เป็น T_t, S_t, R_t แล้วพยากรณ์ (คาบที่ 7)
- ถ่วงน้ำหนักอดีตแบบ geometric ด้วย ETS (คาบที่ 8)
- เลือก model ด้วย AICc และตรวจ residual

สิ่งที่ยังขาด

- ทั้งสองวิธีไม่เคยใช้ **ความสัมพันธ์ระหว่าง y_t กับ y_{t-k}** โดยตรง
- ไม่มีกรอบที่บอกว่าควรมองย้อนกลับไปกี่คาบ
- บน elecequip ทั้ง decomposition และ ETS ยังแพ้ benchmark

คำถามของคาบนี้

ถ้า y_t สัมพันธ์กับค่าของตัวเองในอดีต จะเขียน model ที่ใช้ความสัมพันธ์นั้นตรง ๆ ได้อย่างไร และจะรู้ได้อย่างไรว่าควรใช้ย้อนหลังกี่คาบ

แผนที่ของคาบนี้



- ลำดับนี้เป็นลำดับการทำงานจริง ไม่ใช่แค่ลำดับการสอน ข้ามขั้นไหนไปก็พังที่ขั้นนั้น
- ปิดท้ายด้วยการเทียบ ETS กับ ARIMA บนข้อมูลและช่วงทดสอบเดิมของคาบที่ 7 และ 8

Stationarity

ข้อสมมติที่ทุก model ในคาบนี้ต้องการ

Stationarity คืออะไร

นิยามอย่างไม่เป็นทางการ

อนุกรมเวลาเป็น **stationary** ถ้า **คุณสมบัติเชิงสถิติของมันไม่เปลี่ยนไปตามเวลา**

แล้ว “คุณสมบัติเชิงสถิติ” หมายถึงอะไรบ้าง

- ค่าเฉลี่ย (mean)
- ความแปรปรวน (variance)
- ความแปรปรวนร่วม (covariance)

ข้อสำคัญ

covariance ระหว่าง y_t กับ y_{t-k} ต้องขึ้นกับ **ระยะห่าง k เท่านั้น** ไม่ขึ้นกับว่าอยู่ที่เวลา t ใด นี่คือเงื่อนไขที่ทำให้ “เรียนรู้จากอดีตแล้วใช้กับอนาคต” มีความหมาย

Stationarity

อนุกรมเวลา $\{y_t\}$ เป็น stationary ถ้าการแจกแจงร่วมของ

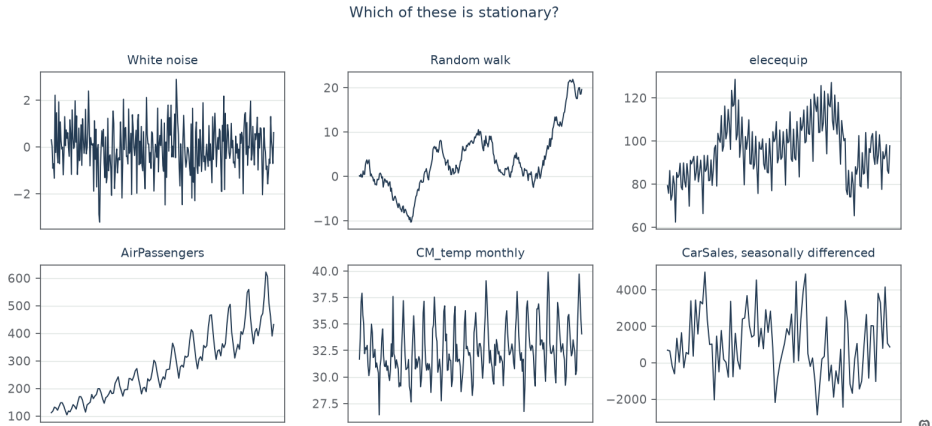
$$(Y_t,\ Y_{t+1},\ \ldots,\ Y_{t+s})$$

ไม่ขึ้นกับ t สำหรับทุกค่าของ s

- ในทางปฏิบัติเราแทบไม่เคยรู้การแจกแจงเหล่านี้
- สิ่งที่ทำได้จริงคือ **หาหลักฐานว่ามัน ไม่ stationary** ซึ่งง่ายกว่ามาก
- เริ่มจากการพล็อตเสมอ แล้วค่อยใช้การทดสอบเป็นตัวยืนยัน

นิยามนี้เข้มกว่าที่ ARIMA ต้องการเล็กน้อย ARIMA ต้องการเพียง weak stationarity คือ mean คงที่ variance จำกัด และ covariance ขึ้นกับ k อย่างเดียว

อันไหน stationary



ตอบก่อนพลิก

หน้าถัดไป ดูที่ “ค่าเฉลี่ยเลื่อนไหม” “ช่วงแกว่งโตขึ้นไหม” และ “มีรูปแบบซ้ำตามฤดูกาลไหม”

อนุกรม	คำตอบ	เหตุผล
White noise	stationary	ไม่มี trend ไม่มี seasonality variance คงที่
Random walk	ไม่ใช่	variance โตตาม t ไม่มีระดับที่ตายตัว
elecequip	ไม่ใช่	มี trend และ cycle จากปี 2008
AirPassengers	ไม่ใช่	มี trend และช่วงแกว่งโตตามระดับ
CM_temp รายเดือน	ไม่ใช่	seasonality แรง แม้ trend เกือบแบน
CarSales หลัง $D = 1$	stationary	ช่วงแกว่งตามฤดูกาลหายไป ระดับแบน

กรณีที่พลาดกันบ่อยที่สุดคือ CM_temp

trend เกือบแบน แต่ **ยังไม่ stationary** เพราะค่าเฉลี่ยของเดือนเมษายนกับเดือนธันวาคมไม่เท่ากัน seasonality เพียงอย่างเดียวก็ตัดสิทธิ์แล้ว ไม่จำเป็นต้องมี trend ด้วย

สรุปสัญญาณว่าไม่ stationary

trend

ระดับเลื่อนขึ้นหรือลงอย่างต่อเนื่อง

seasonality

รูปแบบซ้ำทุก m คาบ

variance เปลี่ยน

ช่วงแกว่งกว้างขึ้นหรือแคบลง

แต่ละอย่างมีวิธีแก้คนละแบบ

- variance เปลี่ยน $\rightarrow$ **แปลงข้อมูล** ด้วย log หรือ Box-Cox
- seasonality $\rightarrow$ **seasonal differencing** (D)
- trend $\rightarrow$ **first differencing** (d)

ทำตามลำดับนี้เสมอ แปลงก่อน แล้วค่อย difference เพราะการ difference ข้อมูลที่ variance ยังไม่นิ่งจะได้อนุกรมที่ variance ยังไม่นิ่งอยู่ดี

Random walk และ unit root

กรณีที่ไม่ stationary ที่ง่ายที่สุด และเป็นต้นแบบของทุกกรณี

Random walk

นิยาม

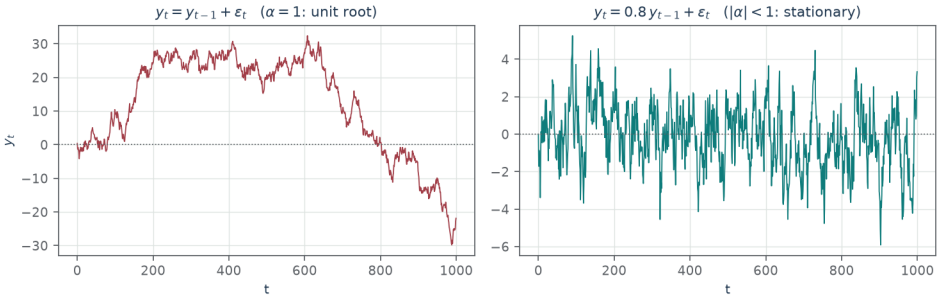
$$y_t = y_{t-1} + \varepsilon_t, \qquad \varepsilon_t \sim N(0, \sigma^2) \text{ เป็น white noise}$$

- ค่าวันนี้คือค่าเมื่อวานบวกสิ่งที่คาดเดาไม่ได้
- แตกย้อนกลับไปจะได้ $y_t = y_0 + \sum_{i=1}^{t} \varepsilon_i$
- ดังนั้น $\text{Var}(y_t) = t\,\sigma^2$ ซึ่ง **โตขึ้นเรื่อย ๆ ไม่มีขอบเขต**

ทำไมจึงสำคัญ

random walk ไม่มีค่าเฉลี่ยระยะยาวให้ลู่เข้า และไม่มี variance ที่คงที่ ทุกครั้งที่กราฟดู “เหมือนมี trend แต่ trend เปลี่ยนทิศไปมา” ให้นึกถึงกรณีนี้ก่อน

ต่างกันที่สัมประสิทธิ์ตัวเดียว



	sd	พิสัย	sd ตามทฤษฎี
random walk ($\alpha = 1$)	14.604	62.196	ไม่มี
AR(1) ที่ $\alpha = 0.8$	1.672	11.166	$1/\sqrt{1 - 0.8^2} = 1.667$

ทั้งสองเส้นขับเคลื่อนด้วย ε_t ชุดเดียวกัน 1000 ค่า ต่างกันเพียง α

Unit root

ในสมการ $y_t = \alpha y_{t-1} + \varepsilon_t$ ถ้า $\alpha = 1$ เราเรียกว่าอนุกรมนี้มี **unit root**

- $|\alpha| < 1$: ค่าที่หลุดออกไปจะถูกดึงกลับเข้าหาค่าเฉลี่ย $\rightarrow$ stationary
- $\alpha = 1$: ไม่มีแรงดึงกลับเลย ผลกระทบของ ε_t อยู่ถาวร $\rightarrow$ ไม่ stationary
- $|\alpha| > 1$: ระเบิดออก ไม่พบในข้อมูลจริงที่มีความหมาย

ประโยคที่ควรจำ

“มี unit root” กับ “ต้อง difference” เป็นเรื่องเดียวกันในทางปฏิบัติ การทดสอบที่จะพูดถึงต่อไปคือการทดสอบว่ามี unit root หรือไม่

Differencing

วิธีทำให้อนุกรมนิ่ง และวิธีรู้ว่าทำมากเกินไป

Differencing แก้ random walk ได้พอดี

จาก random walk ที่ไม่ stationary

$$y_t = y_{t-1} + \varepsilon_t$$

นิยามอนุกรมผลต่าง

$$z_t = y_t - y_{t-1} = \varepsilon_t$$

ผลลัพธ์

z_t คือ white noise ซึ่ง **stationary** อย่างสมบูรณ์

- นี่คือเหตุผลทั้งหมดที่ differencing เป็นเครื่องมือหลักของ ARIMA
- ตัวอักษร **I** ใน ARIMA ย่อมาจาก Integrated ซึ่งหมายถึงจำนวนครั้งที่ต้อง difference

Differencing ซ้ำ และ differencing ตามฤดูกาล

Second-order differencing

ถ้า difference ครั้งเดียวยังไม่พอ

$$z'_t = z_t - z_{t-1} = y_t - 2y_{t-1} + y_{t-2}$$

ในทางปฏิบัติแทบไม่เคยต้องเกิน $d = 2$

Seasonal differencing

หักกับค่าของฤดูกาลเดียวกันรอบก่อน

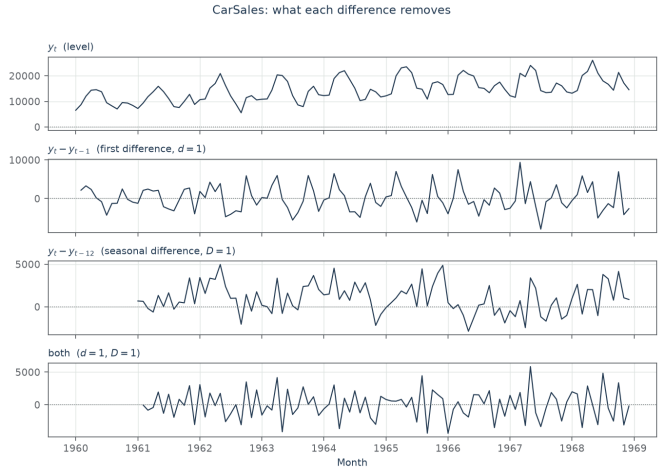
$$z_t = y_t - y_{t-m}$$

m คือความยาวฤดูกาล เช่น $m = 12$ สำหรับข้อมูลรายเดือน

สองอย่างนี้คนละตัวกัน

d นับ first difference ส่วน D นับ seasonal difference ใช้ร่วมกันได้ และในสัญกรณ์ SARIMA จะปรากฏคนละตำแหน่ง

แต่ละ difference เอาอะไรออกไปบ้าง



CarSales ยอดขายรถยนต์รายเดือนในรัฐควิเบก 1960–1968 จำนวน 108 ค่า

ตัวเลขจากภาพที่แล้ว

อนุกรม	n	sd	KPSS p	ADF p	ข้อสรุป
level	108	4525.2	0.0100	0.6633	ไม่ stationary ทั้งคู่
$d = 1$	107	3328.3	0.1000	0.0000	stationary ทั้งคู่
$D = 1$ ($m = 12$)	96	1766.6	0.1000	0.0050	stationary ทั้งคู่
$d = 1$ และ $D = 1$	95	2222.2	0.1000	0.0130	stationary ทั้งคู่

อ่านตารางนี้ให้ครบ

ทั้งสามแถวล่างผ่านการทดสอบหมด แต่ $D = 1$ **อย่างเดียวให้ sd ต่ำที่สุด** การเพิ่ม $d = 1$ เข้าไปอีกทำให้ sd สูงขึ้น จาก 1766.6 เป็น 2222.2 นั่นคือสัญญาณว่า difference เกินความจำเป็น

ทำ seasonal differencing ก่อนเสมอ เพราะบ่อยครั้งมันดึง trend ออกไปด้วยจนไม่ต้องใช้ d เลย ซึ่งเป็นสิ่งที่เกิดขึ้นพอดีกับ CarSales

การทดสอบ stationarity

สองการทดสอบที่สมมติฐานหลักกลับด้านกัน

KPSS และ ADF

KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

H_0 : y_t เป็น stationary

H_a : y_t **ไม่** เป็น stationary

ถ้า **ปฏิเสธ** H_0 ($p < 0.05$) แปลว่า **ต้อง difference**

ADF (Augmented Dickey-Fuller)

H_0 : y_t มี unit root

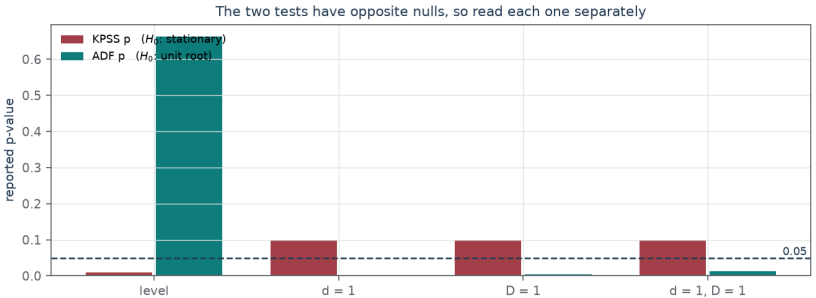
H_a : y_t เป็น stationary

ถ้า **ปฏิเสธ** H_0 ($p < 0.05$) แปลว่า **ไม่ต้อง difference**

สมมติฐานหลักกลับด้านกัน

p ต่ำใน KPSS แปลว่า แย่ แต่ p ต่ำใน ADF แปลว่า ดี นี่คือจุดที่อ่านกลับด้านกันบ่อยที่สุดในคาบนี้ อ่านทีละตัวเสมอ อย่าจำว่า “p ต่ำคือดี”

ผลลัพธ์บน CarSales



	KPSS stat	p	ADF stat	p	ข้อสรุป
level	1.2501	0.0100	−1.2238	0.6633	difference
$d = 1$	0.0224	0.1000	−6.1998	0.0000	พอแล้ว
$D = 1$	0.1630	0.1000	−3.6444	0.0050	พอแล้ว
$d = 1, D = 1$	0.0483	0.1000	−3.3451	0.0130	พอแล้ว

การทดสอบทั้งสองตัวมองไม่เห็น seasonality

	KPSS p	อ่านว่า	ADF p	อ่านว่า
elecequip, level	0.0579	stationary	0.0040	stationary
elecequip, หลัง $D = 1$	0.1000	stationary	0.1107	ไม่ stationary
CarSales, หลัง $D = 1$	0.0974	stationary	0.0020	stationary
CM_temp, หลัง $D = 1$	0.1000	stationary	0.0000	stationary

แถวแรกคือคำเตือน

elecequip ที่ยังไม่ได้ difference **ผ่านการทดสอบทั้งสองตัว** ทั้งที่มันมี seasonality ชัดเจน เพราะทั้ง KPSS และ ADF ถามเรื่อง unit root กับระดับเท่านั้น **seasonality มองไม่เห็นด้วยการทดสอบเหล่านี้**

เลือก D จากกราฟฤดูกาลและ ACF แล้วค่อยใช้การทดสอบเลือก d ทีหลัง ไม่ใช่ทางกลับกัน

แถวที่สองของตารางที่แล้ว

elecequip หลัง $D = 1$: KPSS บอกว่าพอแล้ว ($p = 0.1000$) แต่ ADF บอกว่ายังไม่พอ ($p = 0.1107$)

- ตามธรรมเนียมของ FPP ให้ยึด **KPSS** เป็นตัวตัดสิน d เพราะ H_0 ของมันคือสิ่งที่เราต้องการ การปฏิเสธจึงเป็นหลักฐานเชิงบวกว่าต้อง difference
- แต่เมื่อสองตัวขัดกัน **ไม่มีอะไรใน training set ที่ตัดสินได้** ต้องใช้ข้อมูลที่กันไว้ทดสอบ
- เราจะเห็นราคาของการเลือกผิดในสไลด์สุดท้ายของคาบนี้

และห้ามตัดสินด้วย AICc

เพราะสองทางเลือกนี้มี d ต่างกัน ซึ่งเป็นสิ่งที่ AICc เปรียบเทียบไม่ได้ เหตุผลอยู่ในหัวข้อการเลือก model

ACF และ PACF

เครื่องมืออ่านว่าอดีตกี่คาบยังมีความหมาย

Autocorrelation function (ACF)

แนวคิด

autocorrelation วัด **ความสัมพันธ์เชิงเส้นระหว่างอนุกรมกับตัวมันเองที่เลื่อนไปในอดีต**

Y_t	y_1	$\cdots$	y_{k+1}	$\cdots$	y_t	$\cdots$
Y_{t-k}			y_1	$\cdots$	y_{t-k}	$\cdots$

autocorrelation ที่ lag k

$$r_k = \frac{\sum_{t=k+1}^{T}(y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T}(y_t - \bar{y})^2}$$

ตัวเศษเสีย k พจน์ไป แต่ตัวส่วนยังรวมครบ T พจน์ นี่คือตัวประมาณมาตรฐาน และเป็นตัวเดียวกับที่ `statsmodels.tsa.stattools.acf` คืนค่ามาให้

แถบนัยสำคัญ

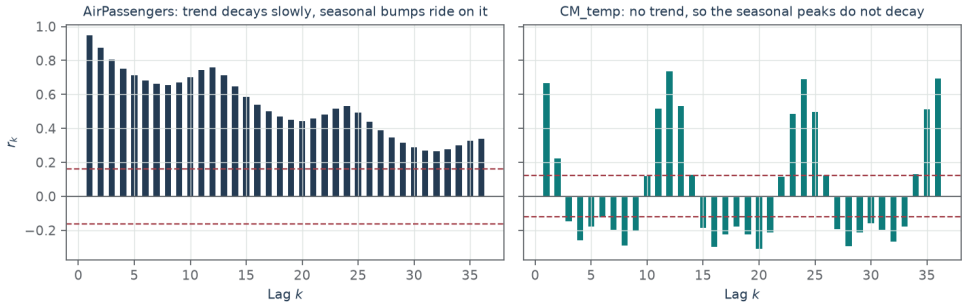
ถ้าอนุกรมเป็น white noise จริง r_k จะกระจายรอบศูนย์ด้วย sd ประมาณ $1/\sqrt{T}$ ดังนั้นแถบ

$$\pm\frac{1.96}{\sqrt{T}}$$

คือช่วงที่ r_k ควรอยู่ข้างใน ประมาณ 95% ของ lag

- ค่าที่ **ออกนอกแถบ** ถือว่าต่างจากศูนย์อย่างมีนัยสำคัญ
- แถบแคบลงเมื่อ T ใหญ่ขึ้น ดังนั้นอนุกรมยาวจะจับความสัมพันธ์เล็ก ๆ ได้ด้วย
- ถ้าดู 40 lag แล้วมี 2 lag หลุดออกนอกแถบ นั่นคือ **สิ่งที่คาดหวังจากความบังเอิญอยู่แล้ว** ไม่ใช่หลักฐาน

trend กับ seasonality หน้าตาต่างกันใน ACF



	r_1	r_6	r_{12}	r_{24}	r_{36}	
AirPassengers	0.948	0.682	0.760	0.532	0.337	มี trend
CM_temp รายเดือน	0.665	-0.126	0.736	0.689	0.695	ไม่มี trend

อ่านสองภาพนั้นอย่างไร

trend

r_k ทุกค่าเป็นบวกและ **ลดลงช้า ๆ** เพราะจุดที่อยู่ใกล้กันในเวลาก็อยู่ใกล้กันในค่า

seasonality

มี **ยอดแหลมที่ lag เป็นพหุคูณของ** m คือ $12, 24, 36$

จุดที่แยกสองอนุกรมนี้ออกจากกัน

- AirPassengers ยอดที่ lag $12, 24, 36$ **ค่อย ๆ จางลง** ($0.760 \to 0.532 \to 0.337$) เพราะ trend ที่หนุนอยู่ข้างใต้จางลง
- CM_temp ยอด **ไม่จางเลย** ($0.736 \to 0.689 \to 0.695$) เพราะไม่มี trend ให้จาง
- CM_temp ยังติดลบระหว่างยอด ($r_6 = -0.126$) หกเดือนหลังเดือนร้อนคือเดือนเย็น อนุกรมที่มี trend จะไม่มีพฤติกรรมนี้

Partial autocorrelation function (PACF)

แนวคิด

PACF ที่ lag k วัด **ส่วนของความสัมพันธ์ที่ lag ก่อนหน้ายังอธิบายไม่ได้**

ถ้า y_t สัมพันธ์กับ y_{t-1} และ y_{t-1} สัมพันธ์กับ y_{t-2} แล้ว y_t ย่อมสัมพันธ์กับ y_{t-2} โดยอัตโนมัติ แม้จะไม่มีความสัมพันธ์โดยตรงเลยก็ตาม ACF จะนับความสัมพันธ์ที่ส่งต่อกันมานี้ด้วย

นิยามเชิงปฏิบัติ

PACF ที่ lag k คือสัมประสิทธิ์ ϕ_{kk} จากการถดถอย

$$y_t = \phi_{k1} y_{t-1} + \phi_{k2} y_{t-2} + \cdots + \phi_{kk} y_{t-k} + \varepsilon_t$$

นั่นคือ “ควบคุม lag ที่อยู่ระหว่างกลางไว้แล้ว เหลือความสัมพันธ์โดยตรงเท่าไร”

เป็นแนวคิดเดียวกับการตีความสัมประสิทธิ์ใน multiple regression ของคาบที่ 5 คือ “เมื่อควบคุมตัวแปรอื่นแล้ว”

AR, MA และ ARIMA

สาม model ที่ประกอบกันเป็นตัวเดียว

Autoregressive model, AR(p)

AR(p)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

- นี่คือ **multiple linear regression** ที่มี $y_{t-1}, \ldots, y_{t-p}$ เป็น predictor และ y_t เป็น response
- ทุกอย่างจากคาบที่ 4–6 ใช้ได้หมด ทั้งการตีความสัมประสิทธิ์ การทดสอบ และการเลือกตัวแปร
- ต่างกันที่ predictor ไม่ได้เป็นอิสระจาก response ในเชิงเวลา จึงต้องการ stationarity มาช่วย

เงื่อนไขของ ϕ

AR(1) จะ stationary ก็ต่อเมื่อ $|\phi_1| < 1$ ซึ่งเป็นเงื่อนไขเดียวกับที่เห็นในสไลด์ random walk ที่ $\phi_1 = 1$ พอดี

Moving average model, MA(q)

MA(q)

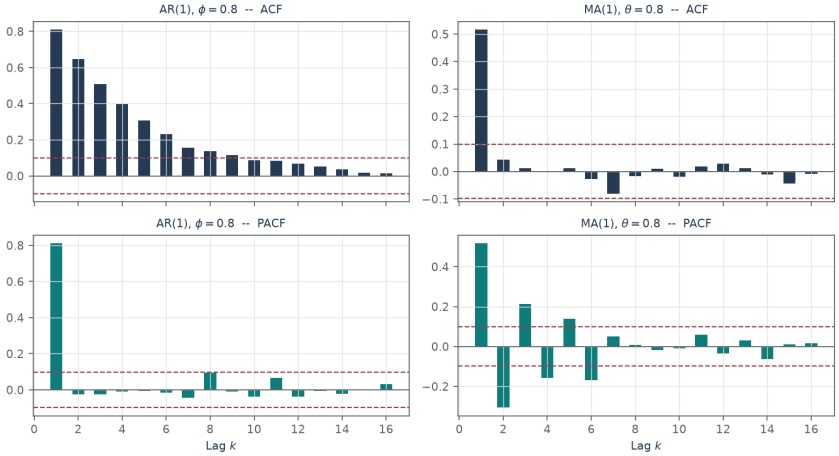
$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

- ใช้ **ความผิดพลาดในอดีต** มาพยากรณ์ ไม่ใช่ค่าในอดีต
- ตีความได้ว่า “แรงกระแทกเมื่อวานยังมีผลตกค้างมาถึงวันนี้เท่าไร”
- ชื่อ moving average ในที่นี้ **คนละความหมาย** กับ moving average ที่ใช้ทำ decomposition ในคาบที่ 7

จุดที่สับสนบ่อย

ε_{t-1} ไม่ใช่ข้อมูลที่สังเกตได้ มันคือสิ่งที่ model คำนวณย้อนกลับมาเอง นี่คือเหตุผลที่ MA ไม่มีสูตรปิดและต้อง fit ด้วยการค้นหาเชิงตัวเลข เช่นเดียวกับ ETS ในคาบที่แล้ว

ลายเซ็นของ AR และ MA ในสองกราฟ



ข้อมูลจำลอง $T = 400$ ที่รู้คำตอบอยู่แล้ว แถบนัยสำคัญ ± 0.098

กฎการอ่านอันดับจากกราฟ

รูปแบบที่เห็น	แปลว่า	ตัวเลขจากภาพที่แล้ว
PACF ตัดหายหลัง lag p, ACF ค่อย ๆ ลด	ARIMA$(p, d, 0)$	AR(1): PACF 0.811 แล้วเหลือ -0.026
ACF ตัดหายหลัง lag q, PACF ค่อย ๆ ลด	ARIMA$(0, d, q)$	MA(1): ACF 0.517 แล้วเหลือ 0.043
ทั้งสองค่อย ๆ ลด ไม่มีตัวไหนตัดหาย	$p, q > 0$	กราฟช่วยไม่ได้

ข้อจำกัดที่ต้องพูดออกมาให้ชัด

กฎสองข้อแรกใช้ได้เมื่อมี **อย่างใดอย่างหนึ่งเป็นศูนย์เท่านั้น** ถ้าทั้ง p และ q ไม่เป็นศูนย์ รูปร่างจะผสมกันจนไม่มีจุดตัดให้เห็น กราฟจึงให้ได้แค่ **รายชื่อผู้สมัคร** ไม่ใช่คำตอบ

และกฎทั้งหมดนี้ใช้กับกราฟของอนุกรม **ที่ difference แล้ว** เสมอ ไม่ใช่อนุกรมดิบ

รวมทั้งสามส่วนเข้าด้วยกัน

$$y'_t = c + \underbrace{\phi_1 y'_{t-1} + \cdots + \phi_p y'_{t-p}}_{\text{AR: ค่าในอดีต}} + \underbrace{\theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}}_{\text{MA: ความผิดพลาดในอดีต}} + \varepsilon_t$$

โดย y'_t คืออนุกรมที่ผ่านการ difference มาแล้ว d ครั้ง

AR: p

ย้อนดูค่าไปกี่คาบ

I: d

difference กี่ครั้ง

MA: q

ย้อนดู error ไปกี่คาบ

รวมมี $p + q$ พจน์ที่ต้องประมาณ บวก c และความแปรปรวนของ ε

ตัวดำเนินการ backshift

$$\mathcal{B}y_t = y_{t-1}, \qquad \mathcal{B}^k y_t = y_{t-k}$$

first difference เขียนได้เป็น $y_t - y_{t-1} = (1-\mathcal{B})y_t$ และ difference d ครั้งคือ $(1-\mathcal{B})^d y_t$

ARIMA(p,d,q) ทั้งสมการในบรรทัดเดียว

$$\underbrace{(1-\phi_1\mathcal{B}-\cdots-\phi_p\mathcal{B}^p)}_{\text{AR}}\underbrace{(1-\mathcal{B})^d}_{\text{I}}y_t \;=\; c+\underbrace{(1+\theta_1\mathcal{B}+\cdots+\theta_q\mathcal{B}^q)}_{\text{MA}}\varepsilon_t$$

ประโยชน์จริงของสัญกรณ์นี้จะเห็นชัดตอนเขียน SARIMA ซึ่งแค่คูณวงเล็บของฤดูกาลเข้าไปอีกชุดหนึ่ง

c กับ d กำหนดพฤติกรรมระยะยาว

c	d	ค่าพยากรณ์ระยะยาว
$= 0$	0	ลู่เข้าศูนย์
$= 0$	1	ลู่เข้าค่าคงที่ที่ไม่ใช่ศูนย์
$= 0$	2	เป็นเส้นตรง
$\neq 0$	0	ลู่เข้าค่าเฉลี่ยของข้อมูล
$\neq 0$	1	เป็นเส้นตรง
$\neq 0$	2	เป็นเส้นโค้งกำลังสอง

เลือก d แล้วก็เท่ากับเลือกรูปร่างของการพยากรณ์ระยะยาวไปด้วย

แถวสุดท้ายแทบไม่เคยสมเหตุสมผล การพยากรณ์ที่โค้งขึ้นเป็นกำลังสองไปตลอดกาลไม่ใช่สิ่งที่ข้อมูลจริงทำ นี่คือเหตุผลเชิงปฏิบัติที่หลีกเลี่ยง $d = 2$ คู่กับค่าคงที่

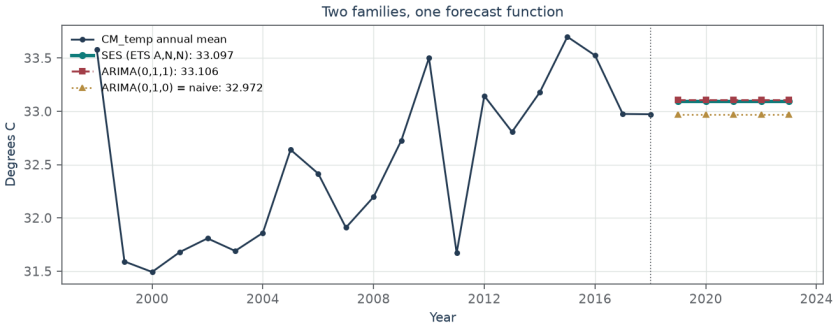
กรณีพิเศษ: model ของคาบที่แล้วอยู่ในนี้หมด

ARIMA	คือ
$(0,1,0)$	naive forecast
$(0,1,1)$	simple exponential smoothing
$(0,2,2)$	Holt's linear method
$(0,1,1)(0,1,1)_m$	Holt-Winters แบบบวก

ทำไมจึงสำคัญ

ETS กับ ARIMA ไม่ใช่คู่แข่งที่ไม่เกี่ยวกัน มันซ้อนทับกันบางส่วน **ETS ทุกตัวที่เป็นเชิงเส้นและมี error แบบบวก มี ARIMA ที่สมมูลกันอยู่** แต่ ETS ที่มี error แบบคูณ และ ARIMA ที่ไม่ stationary หลังจาก difference แล้ว ไม่มีคู่สมมูล

$(0, 1, 1)$ กับ SES บนอนุกรมเดียวกัน



	ค่าพยากรณ์	
SES (ETS A, N, N)	33.0970	$\hat{\alpha} = 0.3143$
ARIMA$(0, 1, 1)$	33.1056	$\hat{\theta}_1 = -0.6483$ จึงได้
		$\alpha = 1 + \theta_1 = 0.3517$
ARIMA$(0, 1, 0)$	32.9721	เท่ากับ y_T พอดี

SARIMA

เพิ่มฤดูกาลเข้าไปอีกชุดหนึ่ง

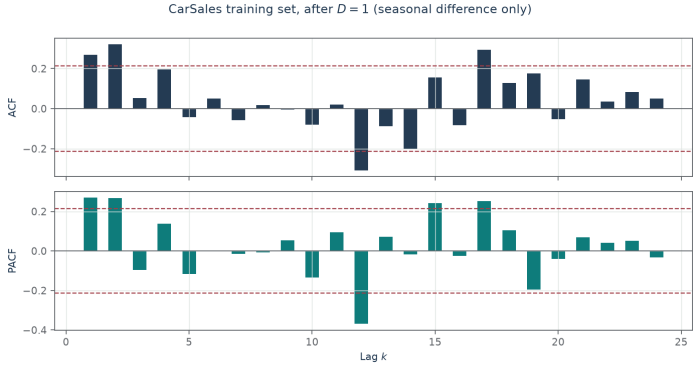
สองชุดพจน์ คูณกัน

$$\underbrace{\Phi_P(\mathcal{B}^m)\,\phi_p(\mathcal{B})}_{\text{AR ฤดูกาล}\times\text{AR ปกติ}}\underbrace{(1-\mathcal{B}^m)^D(1-\mathcal{B})^d}_{\text{difference ทั้งสองแบบ}}y_t \;=\; c+\underbrace{\Theta_Q(\mathcal{B}^m)\,\theta_q(\mathcal{B})}_{\text{MA ฤดูกาล}\times\text{MA ปกติ}}\varepsilon_t$$

- ตัวพิมพ์ใหญ่ P, D, Q ทำงานที่ lag เป็นพหุคูณของ m ตัวพิมพ์เล็กทำงานที่ lag ติดกัน
- เช่น SARIMA$(0,0,2)(0,1,1)_{12}$ คือ MA สองพจน์ที่ lag $1, 2$ บวก MA ฤดูกาลหนึ่งพจน์ที่ lag 12 บนอนุกรมที่ seasonal difference มาแล้วหนึ่งครั้ง
- การคูณกันทำให้เกิดพจน์ที่ lag $13, 14$ ด้วยโดยอัตโนมัติ ซึ่งเป็นสิ่งที่ต้องการ

ใน `statsmodels` เขียนเป็น `order=(0,0,2)` และ `seasonal_order=(0,1,1,12)`

อ่านอันดับจาก CarSales จริง



lag	1	2	3	4	ออกนอกแถบที่ lag
ACF	0.269	0.321	0.053	0.195	$1, 2, 12, 17$
PACF	0.269	0.267	-0.096	0.138	$1, 2, 12, 15, 17$

training set 96 เดือน หลัง $D = 1$ เหลือ $T = 84$ แถบนัยสำคัญ ± 0.214

สิ่งที่อ่านได้

- ACF มีนัยสำคัญที่ lag $1, 2$ แล้วเงียบ $\rightarrow$ q **ราว ๆ** 2
- ยอดติดลบชัดที่ lag 12 $\rightarrow$ **MA ฤดูกาลหนึ่งพจน์ คือ** $Q = 1$
- ไม่มี trend เหลือหลัง $D = 1$ และการทดสอบก็ยืนยันแล้ว $\rightarrow$ $d = 0$

ผู้สมัครที่ได้จากกราฟคือ SARIMA$(0, 0, 2)(0, 1, 1)_{12}$

และนี่คือ model เดียวกับที่ AICc เลือกได้เองในภายหลัง

กราฟกับการค้นหาเชิงตัวเลขให้คำตอบตรงกันในกรณีนี้ ซึ่ง **ไม่ใช่เรื่องที่รับประกันได้** lag 15 และ 17 ที่หลุดออกนอกแถบคือสิ่งที่คาดหวังจากความบังเอิญเมื่อดู 24 lag

การเลือก model

likelihood, AICc และการเปรียบเทียบสองแบบที่ทำไม่ได้

คะแนนของ model มาจาก likelihood

Likelihood

$$L = P(\text{data} \mid \text{model})$$

“ถ้า model นี้เป็นจริง โอกาสที่จะได้ข้อมูลชุดนี้ออกมาเป็นเท่าไร”

- L สูงกว่า แปลว่า model อธิบายข้อมูลได้ดีกว่า
- แต่ **model ที่มีพารามิเตอร์มากกว่าจะได้ L สูงกว่าเสมอ** แม้พารามิเตอร์นั้นจะไม่มีประโยชน์
- จึงต้องมีบทลงโทษตามจำนวนพารามิเตอร์ ซึ่งคือที่มาของ AIC, AICc และ BIC

สำหรับอนุกรมเวลา L คำนวณยากกว่าใน linear regression มาก เพราะการสังเกตแต่ละค่าไม่เป็นอิสระต่อกัน `statsmodels` ใช้ Kalman filter คำนวณให้

ให้ $k = 1$ เมื่อ $c \neq 0$ และ $k = 0$ เมื่อ $c = 0$

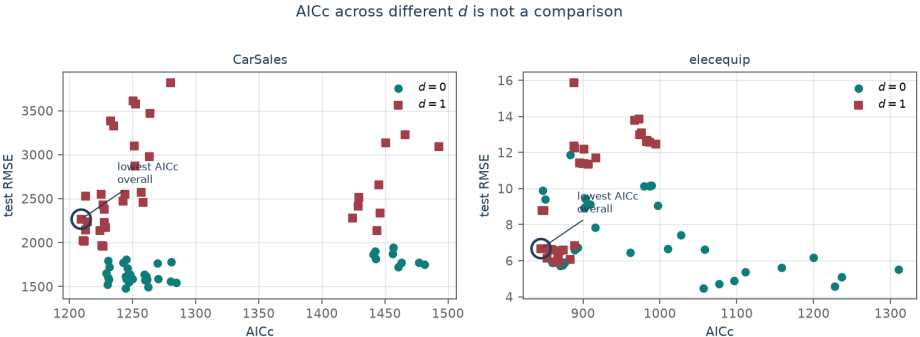
$$\text{AIC} = -2\log(L) + 2(p + q + k + 1)$$

$$\text{AICc} = \text{AIC} + \frac{2(p + q + k + 1)(p + q + k + 2)}{T - p - q - k - 2}$$

$$\text{BIC} = \text{AIC} + \big[\log(T) - 2\big](p + q + k + 1)$$

- ทั้งสามตัว **ยิ่งต่ำยิ่งดี**
- ใช้ **AICc** เป็นหลักสำหรับ ARIMA เพราะพจน์แก้ไขสำคัญเมื่อ T ไม่ได้ใหญ่กว่าจำนวนพารามิเตอร์มากนัก
- BIC ลงโทษหนักกว่าเมื่อ T ใหญ่ จึงมักเลือก model ที่เล็กกว่า

ข้อห้ามข้อที่หนึ่ง: ห้ามเทียบข้าม d



เหตุผล

model ที่ $d = 1$ ถูก fit กับ **ผลต่าง $T - 1$ ค่า** ไม่ใช่ข้อมูล T ค่า likelihood ของสองฝั่งจึงคำนวณบนคนละสิ่ง ตัวเลข AICc ทั้งสองคอลัมน์ **ไม่ได้อยู่บนมาตรเดียวกัน**

ราคาของการเทียบข้าม d บนสามอนุกรม

อนุกรม และผลของการเทียบข้าม	model ที่ AICc เลือกใน d นั้น	AICc	test RMSE
CarSales: เลือก $d = 1$ ซึ่ง แย่กว่า	$d = 0$: $(0,0,2)(0,1,1)$	1229.36	1655.73
	$d = 1$: $(0,1,2)(1,1,1)$	1209.40	2266.97
elecequip: เลือก $d = 1$ ซึ่ง ดีกว่า	$d = 0$: $(2,0,2)(0,1,1)$	847.13	9.88
	$d = 1$: $(2,1,2)(0,1,1)$	845.36	6.67
CM_temp: เลือก $d = 0$ ซึ่ง แย่กว่าเล็กน้อย	$d = 0$: $(0,0,2)(0,1,1)$	630.62	0.9190
	$d = 1$: $(1,1,2)(0,1,1)$	637.22	0.8995

AICc สีแดงคือแถวที่การเทียบข้าม d จะเลือก

สิ่งที่ตารางนี้บอก

การเทียบข้าม d **ไม่ได้ผิดในความหมายว่าเลือกแย่เสมอ** มันผิดในความหมายว่า **ไม่มีความหมาย** บางครั้งบังเอิญถูก บางครั้งบังเอิญผิด และเราไม่มีทางรู้ว่าครั้งนี้เป็นแบบไหน

ข้อห้ามข้อที่สอง: ห้ามเทียบข้ามตระกูล model

AICc ของ ETS กับของ ARIMA เทียบกันไม่ได้

บน CM_temp ช่วงเดียวกัน ARIMA ที่เลือกได้มี AICc $= 630.62$ ส่วน ETS (M, A_d, M) มี AICc $= 715.97$ **ตัวเลขนี้ไม่ได้แปลว่า ARIMA ดีกว่า** เพราะสองตระกูลนิยาม likelihood คนละแบบ

แล้วจะเทียบ ETS กับ ARIMA ได้อย่างไร

ด้วย **test set เท่านั้น** เลือก model ที่ดีที่สุดในแต่ละตระกูลด้วย AICc ของตระกูลนั้น แล้วเอาผู้ชนะสองตัวมาวัดกันบนข้อมูลที่กันไว้ ด้วย metric เดียวกันและ horizon เดียวกัน

ขั้นตอนทั้งหมด เรียงตามลำดับที่ต้องทำ

1. **พล็อตข้อมูล** หา trend, seasonality, การเปลี่ยนแปลงของ variance และค่าผิดปกติ
2. ถ้า variance ไม่นิ่ง **แปลงข้อมูล** ด้วย log หรือ Box-Cox
3. ถ้ามี seasonality เลือก D **จากกราฟและ ACF** ไม่ใช่จากการทดสอบ
4. เลือก d **จาก KPSS** บนอนุกรมที่ seasonal difference แล้ว ถ้า KPSS กับ ADF ขัดกัน ให้เก็บทั้งสองทางเลือกไว้
5. **ตรึง** d **และ** D แล้วดู ACF/PACF เพื่อได้ผู้สมัครเบื้องต้น
6. ค้นหา p, q, P, Q ด้วย **AICc ภายใน** d **ที่ตรึงไว้แล้วเท่านั้น**
7. ตรวจ residual ด้วย ACF และ Ljung-Box
8. วัดบน **test set** เทียบกับ benchmark ที่ไม่มีพารามิเตอร์

ข้อ 6 คือจุดที่พลาดกันมากที่สุด เครื่องมืออัตโนมัติจำนวนมากค้นหา d ไปพร้อมกับ p และ q ในลูปเดียว ถ้าใช้ของแบบนั้นต้องรู้ว่ามันทำอะไรอยู่

ลงมือทำใน Python

API ที่ต้องใช้ และกับดักที่ต้องเลี่ยง

ทดสอบ stationarity และ difference

```python
import pandas as pd
from statsmodels.tsa.stattools import adfuller, kpss

df = pd.read_csv("CarSales.csv", parse_dates=["Month"],
                 date_format="%Y-%m", index_col="Month")
y = df["Sales"].astype("float64").asfreq("MS")   # always set a frequency

# KPSS: H0 = stationary.  ADF: H0 = unit root.  Opposite nulls.
stat, p, lags, crit = kpss(y, nlags="auto")
adf_stat, adf_p, *_ = adfuller(y)

y_seasonal = y.diff(12).dropna()    # D = 1
y_both = y.diff().diff(12).dropna() # d = 1 and D = 1
```

`kpss` ส่ง `InterpolationWarning` เมื่อค่า p ถูกตัดที่ขอบตาราง อย่าปิด warning ทิ้งโดยไม่อ่าน

ACF, PACF และการ fit

```python
from statsmodels.tsa.stattools import acf, pacf
from statsmodels.tsa.statespace.sarimax import SARIMAX

r = acf(y_seasonal, nlags=24, fft=False)
phi = pacf(y_seasonal, nlags=24, method="ywm")
band = 1.96 / len(y_seasonal) ** 0.5      # the dashed lines

res = SARIMAX(train, order=(0, 0, 2), seasonal_order=(0, 1, 1, 12),
              trend="c").fit(disp=False)  # trend="c" only when d = 0

print(res.aicc, res.mle_retvals["converged"])
point = res.forecast(12)
band_df = res.get_forecast(12).summary_frame(alpha=0.05)
```

`trend="c"` เมื่อ $d \geq 1$ จะกลายเป็น deterministic trend ในอนุกรมเดิม ซึ่งเป็นคนละ model กับที่ตั้งใจ

การค้นหาบน grid ที่เขียนเอง

```
import itertools, numpy as np

rows = []
for p, q, P, Q in itertools.product(range(3), range(3), range(2), range(2)):
    try:
        fit = SARIMAX(train, order=(p, 0, q), trend="c",
                      seasonal_order=(P, 1, Q, 12)).fit(disp=False)
    except Exception:
        continue                        # some orders simply will not fit
    if not np.isfinite(fit.aicc):
        continue
    rows.append((fit.aicc, (p, 0, q), (P, 1, Q, 12),
                 fit.mle_retvals.get("converged", True)))

rows.sort()
print(rows[0])                          # lowest AICc, with d fixed at 0
```

36 การ fit ใช้เวลาไม่กี่วินาที d **ไม่ได้อยู่ในลูป** โดยเจตนา

กับดักที่เสียเวลามากที่สุด

สิ่งที่พบ	สิ่งที่ต้องทำ
`pip install pmdarima`	ติดตั้งกับ numpy 2.x ไม่ได้ notebook เก่าต้องลด numpy เป็น `1.26.4` ก่อน **เขียน grid search เองแทน**
`pd.datetime.strptime`	ถูกลบไปแล้ว ใช้ `pd.to_datetime`
`date_parser=`	ถูกลบใน pandas 2.0 ใช้ `date_format=`
`resample("M")`	pandas 3 ใช้ `"ME"` หรือ `"MS"`
ไม่ได้ตั้ง frequency ของ index	`seasonal_order` จะตีความผิด ให้ `asfreq` ก่อนเสมอ
`trend="c"` คู่กับ $d \geq 1$	เปลี่ยนความหมายของ model ใช้เฉพาะเมื่อ $d = 0$

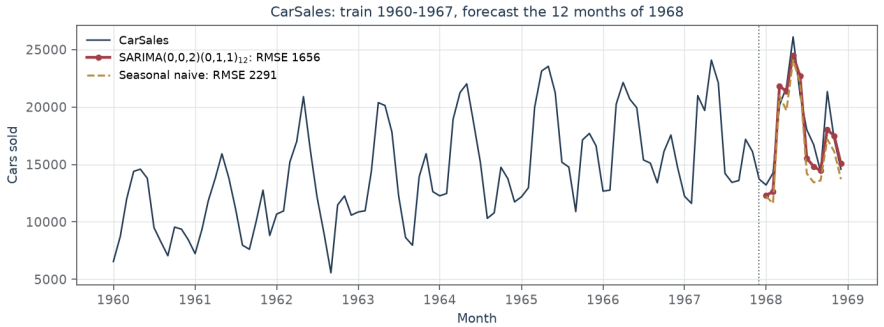
เรื่อง `auto_arima`

tutorial เกือบทั้งหมดบนอินเทอร์เน็ตใช้ `pmdarima.auto_arima` ซึ่งใช้ไม่ได้บน environment ของรายวิชา และมันค้นหา d ไปพร้อมกับ p, q ในลูปเดียวด้วย การเขียน grid search เองจึงได้ทั้ง code ที่รันได้และความเข้าใจว่ากำลังเลือกอะไรอยู่

Residual และความไม่แน่นอน

ต่อจากคาบที่แล้ว ด้วยเครื่องมือเดิม

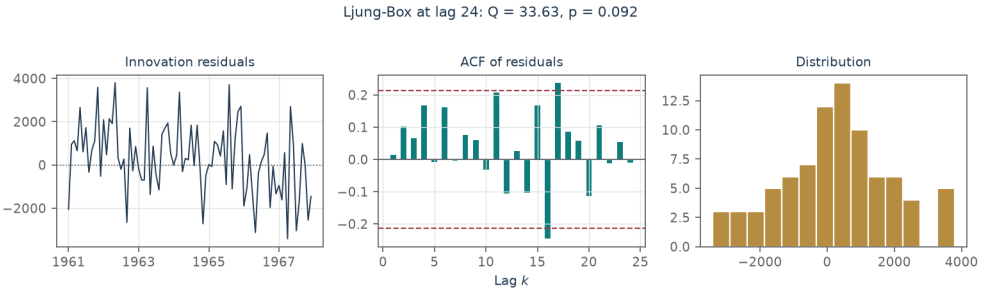
ตัวอย่างที่ทำครบทุกขั้น: CarSales



	test RMSE	
SARIMA$(0,0,2)(0,1,1)_{12}$	1655.7	AICc 1229.36
Seasonal naive	2290.8	ไม่มีพารามิเตอร์เลย

train 96 เดือน ปี 1960–1967 ทดสอบกับ 12 เดือนของปี 1968

ตรวจ residual

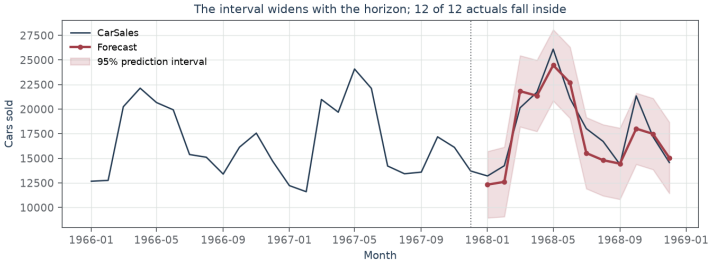


ทิศทางของสมมติฐานกลับด้านจาก KPSS และ ADF

H_0 ของ Ljung-Box คือ “residual เป็น white noise” ดังนั้นในที่นี้ p **สูงคือผลลัพธ์ที่ดี** ได้ $p = 0.092$ จึงยังไม่ปฏิเสธ H_0 แต่ก็ไม่ได้สบายใจนัก

ตัด 12 ค่าแรกทิ้งเพราะ $d + D \cdot m = 0 + 1 \times 12 = 12$ ค่านั้นเป็นช่วงอุ่นเครื่องของ filter ไม่ใช่ innovation จริง

Prediction interval



ค่าจริงตกในช่วง 12 จาก 12 เดือน และความกว้างโตจาก 6759 ที่ $h = 1$ เป็น 7242 ที่ $h = 12$

ช่วง 95% คาดหวัง 11.4 จาก 12 อยู่แล้ว ผลนี้จึง **ไม่ใช่หลักฐานว่าช่วงกว้างเกินไป** ข้อมูล 12 จุดแยกความครอบคลุม 95% ออกจาก 99% ไม่ได้

เช่นเดียวกับคาบที่แล้ว ช่วงนี้คิดโดยสมมติว่าพารามิเตอร์ที่ประมาณได้ถูกต้องแน่นอน ช่วงจริงจึงกว้างกว่าที่แสดงเสมอ

ETS เทียบกับ ARIMA

บนข้อมูลและช่วงทดสอบเดิมของคาบที่ 7 และ 8

แต่ละตระกูลเก่งคนละเรื่อง

ETS

- มีส่วนประกอบชัดเจน level, trend, season
- รองรับ seasonality แบบคูณได้โดยตรง
- ไม่ต้องการ stationarity

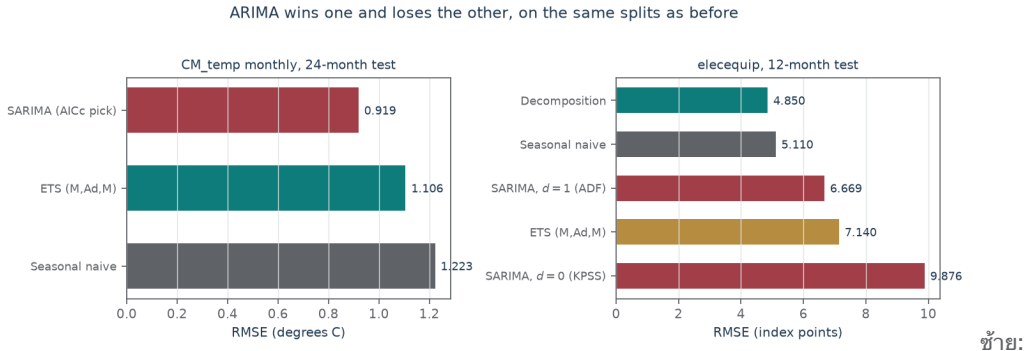
ARIMA

- จับ autocorrelation ที่ซับซ้อนกว่าได้
- ครอบคลุม ETS เชิงเส้นทุกตัวเป็นกรณีพิเศษ
- ต้องการ stationarity ก่อนเสมอ

วิธีตัดสินที่ใช้ได้จริงมีทางเดียว

เลือกตัวที่ดีที่สุดในแต่ละตระกูลด้วย AICc ของตระกูลนั้นเอง แล้ว **วัดกันบน test set** ด้วย metric และ horizon เดียวกัน พร้อมกับ benchmark ที่ไม่มีพารามิเตอร์

ผลการวัดจริงบนสองอนุกรม



ซ้าย: CM_temp รายเดือน ช่วงทดสอบ 24 เดือน ชุดเดียวกับ Lab 08 ขวา: elecequip ช่วงทดสอบ 12 เดือน ชุดเดียวกับคาบที่ 7

CM_temp: ARIMA ชนะชัดเจน

วิธี	RMSE	หมายเหตุ
SARIMA$(0,0,2)(0,1,1)_{12}$	0.9190	AICc 630.62 เลือกภายใน $d = 0$
ETS (M, A_d, M)	1.1060	ผู้ชนะจาก Lab 08 บนชุดเดียวกัน
Seasonal naive	1.2227	ไม่มีพารามิเตอร์เลย

ครั้งแรกในหน่วยนี้ที่ model ชนะ benchmark อย่างขาดลอย

ดีกว่า ETS 16.9% และดีกว่า seasonal naive 24.8% ทั้ง Lab 07 และ Lab 08 จบลงด้วย benchmark ที่ตามมาติด ๆ คราวนี้ไม่ใช่

ทำไมอนุกรมนี้จึงเหมาะกับ ARIMA: seasonality แรงและสม่ำเสมอ trend เกือบแบน และมี 235 จุดให้ fit ซึ่งเพียงพอสำหรับพารามิเตอร์ไม่กี่ตัว

elecequip: ARIMA แพ้ และแพ้อย่างน่าสนใจ

วิธี	RMSE	หมายเหตุ
Decomposition	4.85	จากคาบที่ 7
Seasonal naive	5.11	ไม่มีพารามิเตอร์เลย
SARIMA$(2,1,2)(0,1,1)_{12}$	6.67	ทางเลือกที่ ADF ชี้ ($d=1$)
ETS (M, A_d, M)	7.14	จากคาบที่ 8
Mean	7.53	
SARIMA$(2,0,2)(0,1,1)_{12}$	9.88	ทางเลือกที่ KPSS ชี้ ($d=0$)
Naive	13.99	

ช่องว่างระหว่างสองคำตอบที่ “ถูกต้อง” เท่ากันคือ 3.21

ขณะที่ช่องว่างระหว่างวิธีที่ดีที่สุดกับ ETS คือ 2.29 เท่านั้น **การเสี่ยงทายภายในวิธีเดียวกัน แพงกว่าการเลือกวิธี** และ AICc ของสองทางเลือกนี้ (847.13 กับ 845.36) เทียบกันไม่ได้ จึงตัดสินจาก training set ไม่ได้เลย

กระบวนการเดียวกัน code ชุดเดียวกัน วินัยการแบ่งข้อมูลเดียวกัน

อนุกรมหนึ่งให้รางวัลกับ model อีกอนุกรมหนึ่งลงโทษ ความต่างอยู่ที่ **ตัวข้อมูล ไม่ใช่ที่ฝีมือการทำ**

- elecequip มี **cycle จากวิกฤตปี 2008** ซึ่งไม่ใช่ seasonality เพราะไม่ได้เกิดซ้ำตามรอบที่แน่นอน และไม่ใช่ trend เพราะไม่ได้ไปทางเดียว
- **ไม่มี model ใดในหน่วยนี้มีส่วนประกอบรองรับ cycle** ทั้ง decomposition, ETS และ ARIMA
- decomposition ได้เปรียบเพราะ seasonally adjusted series ดูดซับ cycle ไปไว้ใน trend

บทเรียนที่ต้องเอากลับไป

benchmark ไม่ใช่พิธีกรรม ถ้า model ที่มี 17 พารามิเตอร์แพ้ seasonal naive ที่ไม่มีพารามิเตอร์เลย คำตอบที่ถูกต้องคือส่ง seasonal naive ไม่ใช่หาเหตุผลให้ model

สรุปคาบที่ 9

1. stationary คือคุณสมบัติเชิงสถิติไม่เปลี่ยนตามเวลา สัญญาณว่าไม่ใช่คือ trend, seasonality และ variance ที่เปลี่ยน
2. random walk คือกรณีที่มี unit root การ difference หนึ่งครั้งเปลี่ยนมันเป็น white noise
3. KPSS และ ADF มี H_0 กลับด้านกัน ทั้งคู่มองไม่เห็น seasonality และ p-value ถูกตัดที่ขอบตาราง ส่วน over-differencing ไม่ error แต่ทำให้ sd เพิ่มและ r_1 ติดลบมาก
4. ACF บอก q PACF บอก p และทั้งคู่ช่วยไม่ได้เมื่อ $p, q > 0$ พร้อมกัน
5. ARIMA รวม AR, differencing และ MA เข้าด้วยกัน โดย c กับ d กำหนดรูปร่างของการพยากรณ์ระยะยาว
6. naive, SES และ Holt เป็นกรณีพิเศษของ ARIMA
7. เลือก D จากกราฟ เลือก d จาก KPSS แล้วใช้ AICc เลือก p, q, P, Q **ภายใน d ที่ตรึงไว้**
8. AICc เทียบข้าม d ไม่ได้ และเทียบข้าม ETS กับ ARIMA ไม่ได้ ใช้ test set เท่านั้น

ปฏิบัติการที่ 9 ทำครบทุกขั้นบน CarSales และปิดท้ายด้วยการวัด ETS กับ ARIMA บน CM_temp ชุดเดียวกับ Lab 08

อ่านเพิ่มเติม

Hyndman & Athanasopoulos, Forecasting: Principles and Practice, 2nd ed.

- §8.1 stationarity และ differencing
- §8.2 สัญกรณ์ backshift
- §8.3 autoregressive models
- §8.4 moving average models
- §8.5 ARIMA, c และ d
- §8.6 การประมาณและ AICc
- §8.9 seasonal ARIMA
- §8.10 ARIMA เทียบกับ ETS

ฉบับที่ 3 ย้ายเนื้อหาบทที่ 8 ทั้งหมดไปเป็นบทที่ 9 โดยหัวข้อย่อยเรียงเหมือนเดิม ตำราทั้งสองฉบับอ่านฟรีที่ `otexts.com`