Logistic Regression 1

การบรรยายที่ 10: จาก regression สู่ classification, odds, log-odds และ likelihood

อาจารย์สิปปนนท์ กิติมูล

ภาคการศึกษาที่ 1/2569

คำตอบไม่ได้เป็นตัวเลขอีกต่อไป แต่เป็นคำว่า “ใช่” หรือ “ไม่ใช่” และสิ่งที่เราทำนายจริง ๆ คือโอกาส

เรามาถึงตรงนี้ได้อย่างไร

สิ่งที่ทำมาแล้ว

- **Regression** (คาบที่ 4–6): ทำนาย $Y \in \mathbb{R}$ จาก $X_1, \ldots, X_p$
- **Forecasting** (คาบที่ 7–9): ทำนาย y_{T+h} จาก $y_1, \ldots, y_T$

สิ่งที่ยังทำไม่ได้

- ทำนาย Y ที่เป็น **หมวดหมู่** เช่น จะผิดนัดชำระหรือไม่ จะเป็นโรคหัวใจหรือไม่
- ค่าเฉลี่ยของ “ใช่” กับ “ไม่ใช่” ไม่มีความหมาย

ทั้งสามแบบเป็น **supervised learning**: เรามีคู่ (x_i, y_i) ที่รู้คำตอบ และต้องการฟังก์ชันที่ทำนาย y ของ x ใหม่

แผนที่ของคาบนี้

1. Classification และข้อมูล `Default`
2. ทำไม linear regression จึงใช้ไม่ได้
3. Logistic function
4. Odds, log-odds และการตีความสัมประสิทธิ์
5. การประมาณค่าด้วย maximum likelihood
6. การอ่านผลลัพธ์ และ multiple logistic regression
7. การเตรียมข้อมูล (Framingham) และกับดักใน Python
8. จากความน่าจะเป็นสู่การจำแนก

อ่านประกอบ: ISLR §4.1–4.3.4 คาบหน้าต่อด้วยการประเมิน model และ multinomial logistic regression (§4.3.5)

Classification

เมื่อ Y เป็นหมวดหมู่ ไม่ใช่ตัวเลข

ทำนายโอกาส ไม่ใช่ทำนายป้ายชื่อ

- ตัวอย่างงาน classification: อีเมลนี้เป็น spam ไหม, ผู้ป่วยจะเป็นโรคหัวใจภายใน 10 ปี ไหม, ลูกค้าจะผิดนัดชำระหนี้ไหม
- เราจะไม่ทำนาย 0 หรือ 1 ตรง ๆ แต่ทำนาย

$$p(X) = \Pr(Y = 1 \mid X)$$

- แล้วค่อยตัดสินใจภายหลัง เช่น ทำนาย $\hat{y} = 1$ เมื่อ $p(X) > 0.5$

ทำไมโอกาสจึงมีประโยชน์กว่า

ธนาคารที่รู้ว่าลูกค้าคนหนึ่งมีโอกาสผิดนัด 0.06 กับอีกคน 0.59 เรียงลำดับความเสี่ยงได้ ตั้งวงเงินได้ และเลือกเกณฑ์ตัดเองได้ ส่วนป้ายชื่อ “ไม่ผิดนัด” ทั้งสองคนทิ้งข้อมูลนั้นไปหมด

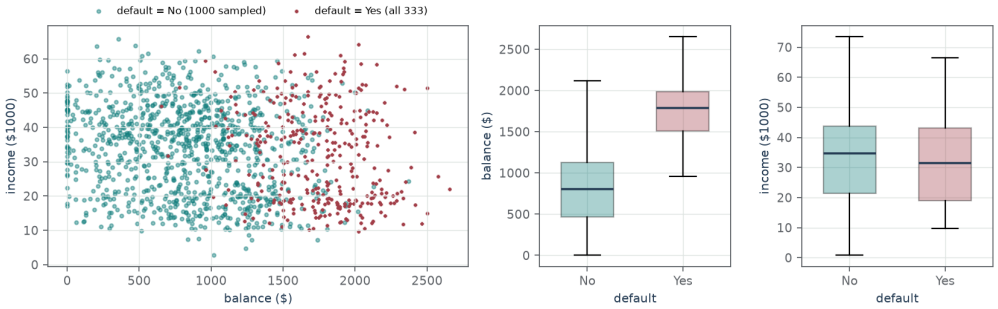
ข้อมูล `Default` (ISLR)

ตัวแปร	ความหมาย
`default`	ผิดนัดชำระบัตรเครดิต (Yes/No)
`student`	เป็นนักศึกษาไหม (Yes/No)
`balance`	ยอดค้างชำระเฉลี่ย ($)
`income`	รายได้ต่อปี ($)

- $n = 10000$ คน ข้อมูลจำลอง
- ผิดนัด 333 คน คิดเป็น 3.33%
- เป็นนักศึกษา 2944 คน

เป็นชุดเดียวกับที่ ISLR บทที่ 4 ใช้ ตัวเลขทุกตารางในคาบนี้จึงตรงกับในหนังสือ โหลดจาก commit ที่ pin ไว้ของ `intro-stat-learning/ISLP` ชุดเดียวกับ Lab 06

ดูข้อมูลก่อน



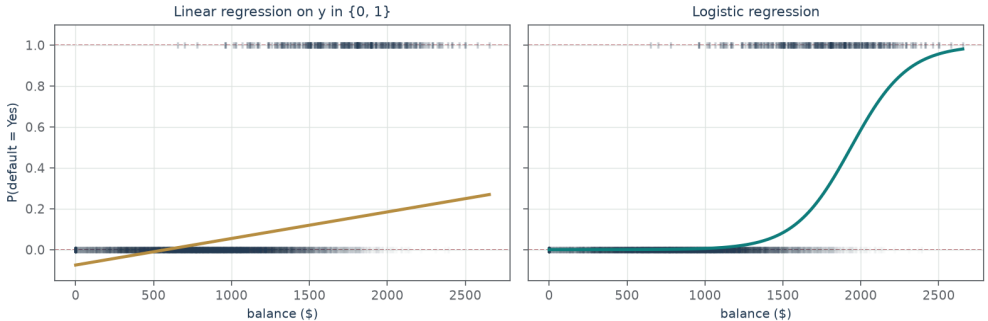
	ไม่ผิดนัด	ผิดนัด
ค่าเฉลี่ย balance	803.9	1747.8
ค่าเฉลี่ย income	33566	32089

balance แยกสองกลุ่มได้ชัด ส่วน income แทบไม่ต่างกัน

ทำไมไม่ใช้ linear regression

ลองดูว่าจะเกิดอะไรขึ้น

ลองเข้ารหัส $Y \in \{0, 1\}$ แล้วใช้ OLS



ขีดสั้นแต่ละขีดคือลูกค้าหนึ่งคน ที่ $y = 0$ หรือ $y = 1$ ซ้าย: linear regression ขวา: logistic regression บนข้อมูลชุดเดียวกัน

ปัญหาที่เห็นจากภาพซ้าย

linear probability model

$$\hat{p}(x) = -0.075192 + 0.000130\,x$$

- ค่าที่ fit ได้ **ติดลบ** 3123 **คน** จาก 10000
- ต่ำสุด -0.0752 สูงสุดเพียง 0.2695
- เส้นตัดศูนย์ที่ `balance` $= 579.0$

สิ่งที่ผิด

- “ความน่าจะเป็น” ติดลบไม่มีความหมาย
- เส้นตรงไม่มีทางอยู่ใน $[0, 1]$ ตลอด ถ้า x ไปไกลพอ
- ลูกค้าที่เสี่ยงที่สุดยังได้ไม่ถึง 0.27

ในกรณี 2 กลุ่ม OLS ยังพอใช้จัดอันดับได้ แต่ตีความเป็นความน่าจะเป็นไม่ได้

มากกว่าสองกลุ่มยิ่งแย่

- สมมติทำนายอาการของผู้ป่วยในห้องฉุกเฉิน แล้วเข้ารหัส

$$Y = \begin{cases} 1 & \text{stroke} \\ 2 & \text{drug overdose} \\ 3 & \text{epileptic seizure} \end{cases}$$

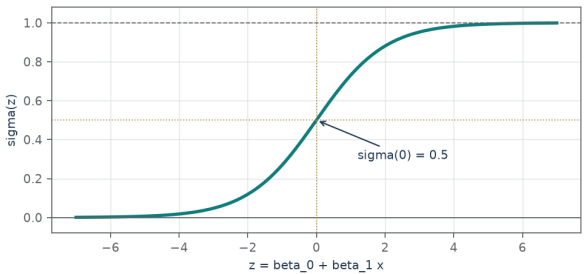
- การเข้ารหัสนี้ **บังคับลำดับ** ให้ overdose อยู่ “ระหว่าง” stroke กับ seizure
- และบังคับให้ระยะห่าง 1 ถึง 2 เท่ากับ 2 ถึง 3
- เข้ารหัสลำดับอื่นก็ได้ model คนละตัว คำทำนายคนละชุด

นี่คือตัวอย่างใน ISLR §4.2 เราจะกลับมาที่ปัญหาหลายกลุ่มในคาบหน้าด้วย multinomial logistic regression

Logistic function

ฟังก์ชันที่รับจำนวนจริงอะไรก็ได้ แล้วคืนค่าใน $(0, 1)$

Sigmoid



$$\sigma(z) = \frac{1}{1+e^{-z}} = \frac{e^z}{1+e^z}$$

- $z \to -\infty \Rightarrow \sigma(z) \to 0$
- $z \to \infty \Rightarrow \sigma(z) \to 1$
- $\sigma(0) = 0.5$
- $\sigma(-z) = 1 - \sigma(z)$

z	-4	-2	0	2	4
$\sigma(z)$	0.0180	0.1192	0.5000	0.8808	0.9820

ใส่ linear predictor เข้าไปใน sigmoid

$$p(X) = \Pr(Y = 1 \mid X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}$$

- ส่วน $\beta_0 + \beta_1 X$ เหมือน linear regression ทุกอย่าง
- sigmoid แค่ “บีบ” ผลลัพธ์ให้อยู่ใน $(0, 1)$ เสมอ ไม่ว่า X จะเป็นเท่าใด
- $\beta_1 > 0$: $p(X)$ เพิ่มเมื่อ X เพิ่ม, $\beta_1 < 0$: ลดลง
- กราฟขวาของภาพเมื่อสักครู่คือ model นี้บน `Default`

ใน `Default` เมื่อ fit แล้วได้ $\hat{\beta}_0 = -10.6513$ และ $\hat{\beta}_1 = 0.005499$ วิธีหาค่าทั้งสองอยู่ในหัวข้อ likelihood

ลองทายก่อน

ด้วย $\hat{\beta}_0 = -10.6513$ และ $\hat{\beta}_1 = 0.005499$

ลูกค้าที่มี balance $1000 กับ $2000 มีโอกาสผิดนัดเท่าใด

1. **คำนวณ $\eta = \hat{\beta}_0 + \hat{\beta}_1 x$ ก่อน**
2. **แล้วแทนใน $\sigma(\eta) = 1/(1 + e^{-\eta})$**

ยอดค้างเพิ่มเป็นสองเท่า ถ้าเป็น linear regression คำตอบจะเพิ่มขึ้นเป็นจำนวนคงที่ ลองดูว่าที่นี่เป็นอย่างนั้นไหม

balance	η	$\hat{p}$	
1000	-5.1524	0.00575	น้อยกว่า 1 ใน 100
1500	-2.4030	0.08295	
2000	0.3465	0.58577	มากกว่าครึ่ง
2500	3.0960	0.95673	

- η เพิ่มทีละ 2.749 เท่ากันทุกช่วง \$500 **แต่ $\hat{p}$ ไม่ได้เพิ่มเท่ากัน**
- จาก \$1000 ไป \$1500 เพิ่ม 0.077 จาก \$1500 ไป \$2000 เพิ่ม 0.503
- $\hat{p} = 0.5$ พอดีเมื่อ $\eta = 0$ คือที่ balance $= -\hat{\beta}_0/\hat{\beta}_1 = 1937.0$

Odds และ log-odds

ภาษาที่ทำให้ β_1 มีความหมาย

Odds

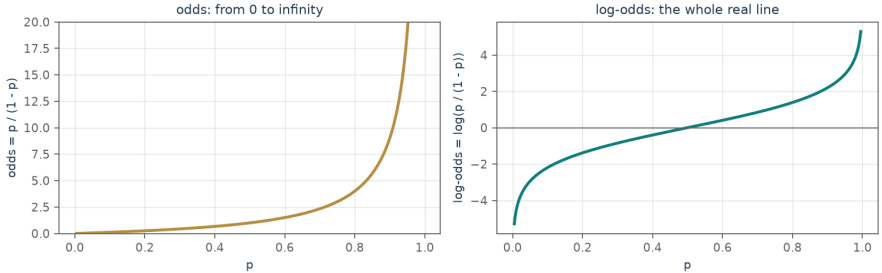
$$\text{odds} = \frac{p}{1-p}$$

p	odds	อ่านว่า
0.10	0.1111	1 ต่อ 9
0.20	0.2500	1 ต่อ 4
0.50	1.0000	1 ต่อ 1
0.75	3.0000	3 ต่อ 1
0.90	9.0000	9 ต่อ 1

กลับจาก odds เป็นความน่าจะเป็นได้เสมอ: $p = \text{odds}/(1 + \text{odds})$

- odds อยู่ใน $[0, \infty)$
- $p = 0.2$ คือ “5 คน ผิดนัด 1 คน” odds คือ ผิดนัด 1 ต่อ ไม่ผิดนัด 4
- ภาษาของการพนันม้า: “3 ต่อ 1”

Log-odds คือส่วนที่เป็นเส้นตรง



$$\log\left(\frac{p(X)}{1-p(X)}\right) = \beta_0 + \beta_1 X$$

log-odds มีอีกชื่อหนึ่งว่า **logit** และเป็นฟังก์ชันผกผันของ sigmoid: $\text{logit}(\sigma(z)) = z$

ตีความ β_1

X เพิ่ม 1 หน่วย

- log-odds เพิ่ม β_1 **เสมอ** ไม่ว่าเริ่มจากตรงไหน
- odds **คูณด้วย** e^{β_1} เรียกว่า **odds ratio**

บน `Default`

- $e^{\hat{\beta}_1} = 1.005514$ ต่อ \$1
- $e^{100\hat{\beta}_1} = 1.7331$ ต่อ \$100

ยอดค้างเพิ่ม \$100 odds ของการผิดนัดเพิ่มเป็น 1.73 เท่า

สิ่งที่ ไม่ ควรพูด

"ยอดค้างเพิ่ม \$1 โอกาสผิดนัดเพิ่ม 0.0055" ผิด เพราะ β_1 อยู่บนสเกล log-odds ไม่ใช่สเกลความน่าจะเป็น

แล้วความน่าจะเป็นเปลี่ยนเท่าใด

$$\frac{\partial p}{\partial x} = \beta_1 \, p \, (1 - p)$$

ที่ p เท่ากับ	p เพิ่มต่อ \$100
0.01	0.0054
0.10	0.0495
0.50	0.1375
0.90	0.0495

- ขึ้นกับว่าอยู่ตรงไหนของเส้นโค้ง
- ชันที่สุดเมื่อ $p = 0.5$
- ใกล้ 0 หรือ 1 แทบไม่ขยับ

จึงรายงาน β_1 เป็น odds ratio เพราะเป็นตัวเลขเดียวที่ใช้ได้ทั้งเส้น ถ้าต้องการพูดเป็นความน่าจะเป็น ให้คำนวณ $\hat{p}$ ที่สองค่า x ที่สนใจแล้วเทียบกัน

Odds ratio ไม่ใช่อัตราส่วนของความน่าจะเป็น

	นักศึกษา	ไม่ใช่นักศึกษา
สัดส่วนผิดนัด	0.0431	0.0292

- อัตราส่วนความน่าจะเป็น $0.0431/0.0292 = 1.4776$
- odds ratio $= 1.4991$
- สองค่านี้ใกล้กันเพราะการผิดนัด **เกิดน้อย**: เมื่อ p เล็ก $p/(1-p) \approx p$

เมื่อเหตุการณ์ไม่ได้เกิดน้อย

ทั้งสองค่าห่างกันมาก ข่าวที่เขียนว่า “เสี่ยงเพิ่มขึ้น 2 เท่า” จาก odds ratio $= 2$ อาจเป็นการอ่าน odds ratio ผิดเป็นอัตราส่วนความน่าจะเป็น

Maximum likelihood

วิธีหา $\hat{\beta}$ เมื่อไม่มี least squares ให้ใช้

ทำไมไม่ใช้ least squares

- Y มีค่าแค่ 0 กับ 1 error จึงไม่ใช่ normal และ variance ขึ้นกับ p
- สิ่งที่อยากได้จริง ๆ คือ **ความน่าจะเป็นที่สอดคล้องกับข้อมูล**

หลักการของ likelihood

เลือก β_0, β_1 ที่ทำให้ข้อมูลที่เห็นจริง **มีโอกาสเกิดขึ้นมากที่สุด**

- ลูกค้าที่ผิดนัดจริง ($y_i = 1$) ควรได้ $\hat{p}(x_i)$ สูง
- ลูกค้าที่ไม่ผิดนัด ($y_i = 0$) ควรได้ $\hat{p}(x_i)$ ต่ำ

เป็นหลักการเดียวกับที่ AICc ในคาบที่ 8–9 ใช้ และสำหรับ linear regression ที่ error เป็น normal มันให้คำตอบเดียวกับ least squares

Likelihood

$$\ell(\beta_0, \beta_1) = \prod_{i:\, y_i=1} p(x_i) \prod_{i:\, y_i=0} \big(1 - p(x_i)\big) = \prod_{i=1}^{n} p(x_i)^{y_i} \big(1 - p(x_i)\big)^{1-y_i}$$

เอา log ทั้งสองข้าง แล้วแทน $p(x_i) = \sigma(\eta_i)$ โดย $\eta_i = \beta_0 + \beta_1 x_i$

$$\log \ell = \sum_{i=1}^{n} \Big[y_i \log p(x_i) + (1 - y_i) \log\big(1 - p(x_i)\big) \Big] = \sum_{i=1}^{n} \Big[y_i\, \eta_i - \log\big(1 + e^{\eta_i}\big) \Big]$$

รูปสุดท้ายคือรูปที่ใช้เขียน code: ไม่ต้องคำนวณ $\log p$ ของค่าที่ใกล้ศูนย์ จึงไม่เกิด $\log 0$

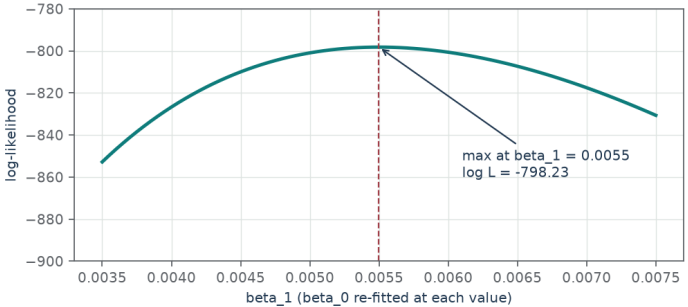
สูตรที่เห็นในเอกสารบางฉบับ

$$L = \prod_{i=1}^{n} p(x_i) = \prod_{i=1}^{n} \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}}$$

- สูตรนี้ใช้ $p(x_i)$ กับ **ทุกคน** รวมคนที่ $y_i = 0$ ด้วย
- จะทำให้ L มากขึ้นได้เรื่อย ๆ ด้วยการดัน $p(x_i) \to 1$ ให้ทุกคน
- ค่าที่มากที่สุดไม่มีอยู่จริง: optimiser จะวิ่งไป $\beta_0 \to \infty$

สูตรที่ถูกต้องต้องให้ $1 - p(x_i)$ กับคนที่ $y_i = 0$ ซึ่งก็คือเลขชี้กำลัง y_i และ $1 - y_i$ ในหน้าที่แล้ว

Log-likelihood มีจุดสูงสุด



β_1	0.004	0.005	0.005499	0.006	0.007
β_0 ที่ดีที่สุด	-8.2991	-9.8540	-10.6513	-11.4631	-13.1088
$\log \ell$	-826.72	-800.97	-798.23	-800.65	-817.52

model ที่ไม่มี X เลย (intercept อย่างเดียว) ได้ $\log \ell = -1460.32$

ไม่มีสูตรปิด ต้องหาเชิงตัวเลข

- linear regression มีสูตรปิด $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ (คาบที่ 5)
- logistic regression **ไม่มี** ต้องค้นหาด้วย iterative algorithm เช่น Newton–Raphson
- ข่าวดี: $\log \ell$ ของ logistic regression เป็น **concave** มีจุดสูงสุดจุดเดียว

สิ่งที่ `statsmodels` พิมพ์ออกมา

```
Optimization terminated successfully.
Current function value: 0.079823
Iterations 10
```

`function value` คือ $-\log \ell / n = 798.23/10000$ ถ้าเห็นคำว่า `ConvergenceWarning` แปลว่าการค้นหายังไม่จบ ค่าสัมประสิทธิ์ที่ได้ยังไม่ใช่คำตอบ

อ่านผลลัพธ์

เครื่องมือเดิมจากคาบที่ 4–5 แค่เปลี่ยน t เป็น z

ISLR Table 4.1: `default ~ balance`

	Coefficient	Std. error	z-statistic	p-value
Intercept	-10.6513	0.3612	-29.49	< 0.0001
`balance`	0.0055	0.0002	24.95	< 0.0001

- $z = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$ อ่านเหมือน t ในคาบที่ 4
- $H_0 : \beta_1 = 0$ แปลว่า $p(X)$ ไม่ขึ้นกับ `balance`
- $z = 24.95$ ปฏิเสธ H_0 อย่างชัดเจน

ใช้ z ไม่ใช่ t เพราะทฤษฎีของ maximum likelihood ให้ $\hat{\beta}$ มีการแจกแจงแบบ normal โดยประมาณเมื่อ n ใหญ่

ใน statsmodels

```python
import pandas as pd
import statsmodels.formula.api as smf

df = pd.read_csv(URL)                              # the pinned ISLP Default.csv
df["y"] = (df["default"] == "Yes").astype(int)   # 0/1 target, not "Yes"/"No"

fit = smf.logit("y ~ balance", data=df).fit()
print(fit.summary())

p_hat = fit.predict(pd.DataFrame({"balance": [1000, 2000]}))
print(p_hat)            # 0.00575, 0.58577 -- probabilities, not labels
```

formula API ใส่ intercept ให้อัตโนมัติ แต่ `sm.Logit(y, X)` แบบ array **ไม่ใส่** ดูหัวข้อกับดักด้านล่าง

Predictor หลายตัว

และตัวอย่างที่เครื่องหมายกลับด้าน

Predictor แบบหมวดหมู่: `student`

ISLR Table 4.2: `default ~ student`

	Coef.	p
Intercept	-3.5041	< 0.0001
`student[Yes]`	0.4049	0.0004

สรุปได้ไหมว่าธนาคารควรระวังนักศึกษามากกว่า เก็บคำถามนี้ไว้ก่อน

- dummy variable แบบเดียวกับคาบที่ 6: baseline คือ “ไม่ใช่นักศึกษา”
- $\hat{\beta}_1 > 0$: นักศึกษา **ผิดนัดมากกว่า**
- odds ratio 1.4991

Multiple logistic regression

$$\log\left(\frac{p(X)}{1-p(X)}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

ISLR Table 4.3: `default ~ balance + income + student`

	Coefficient	Std. error	z	p-value
Intercept	-10.8690	0.4923	-22.08	< 0.0001
`balance`	0.0057	0.0002	24.74	< 0.0001
`income` ($1000)	0.0030	0.0082	0.37	0.7115
`student[Yes]`	-0.6468	0.2363	-2.74	0.0062

`income` วัดเป็นพันดอลลาร์ ถ้าใช้หน่วยดอลลาร์ สัมประสิทธิ์จะเป็น 3.033×10^{-6} แต่ $z = 0.37$ เท่าเดิม หน่วยเปลี่ยนตัวเลข ไม่เปลี่ยนข้อสรุป

เครื่องหมายของ `student` กลับด้าน

`student` ตัวเดียว

$+0.4049$

นักศึกษาผิดนัด **มากกว่า**

เมื่อมี `balance` และ `income` ด้วย

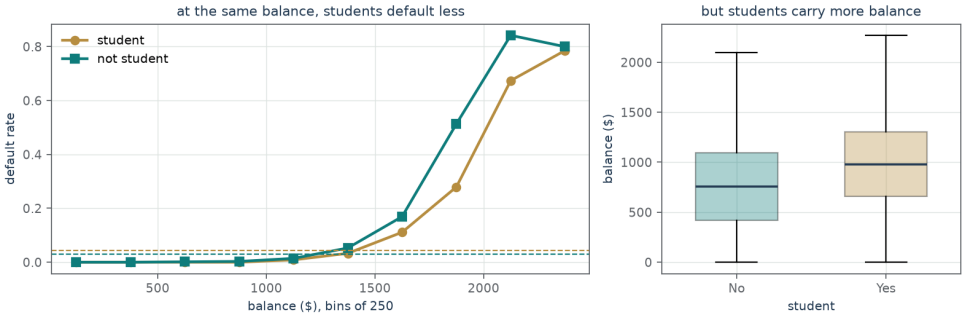
-0.6468

นักศึกษาผิดนัด **น้อยกว่า**

อันไหนถูก?

ลองอธิบายก่อนเปิดหน้าถัดไป ใบ้: คาบที่ 5 เคยบอกว่าสัมประสิทธิ์ใน multiple regression แปลว่า “เมื่อควบคุมตัวแปรอื่นให้คงที่”

Confounding



เส้นประคือสัดส่วนผิดนัดรวมของแต่ละกลุ่ม: นักศึกษา 0.0431 ไม่ใช่นักศึกษา 0.0292

ทั้งสองคำตอบถูก แต่ตอบคนละคำถาม

- นักศึกษามี balance เฉลี่ย 987.8 ส่วนคนอื่น 771.8
- balance สูงคือสาเหตุหลักของการผิดนัด
- **ที่ balance เท่ากัน** นักศึกษาผิดนัดน้อยกว่า (เส้นทึบในภาพซ้าย)
- แต่ **โดยรวม** นักศึกษาผิดนัดมากกว่า เพราะถือยอดค้างสูงกว่า (เส้นประ)

balance $1500, income $40k	นักศึกษา	ไม่ใช่นักศึกษา
$\hat{p}$ จาก model เต็ม	0.0579	0.1050

ธนาคารที่ **ไม่รู้** ยอดค้างของลูกค้า: นักศึกษาเสี่ยงกว่า ธนาคารที่ **รู้** ยอดค้าง: นักศึกษาเสี่ยงน้อยกว่าคนอื่นที่ยอดเท่ากัน
odds ratio ที่ปรับแล้วคือ 0.5237

การเตรียมข้อมูล

ข้อมูล Framingham และสิ่งที่ต้องทำก่อน `.fit()`

Framingham Heart Study

- ผู้เข้าร่วม 4240 คน ตัวแปร 16 ตัว
- `TenYearCHD` $= 1$: เป็นโรคหลอดเลือดหัวใจภายใน 10 ปี
- predictor: เพศ อายุ การสูบบุหรี่ ความดัน คอเลสเตอรอล น้ำตาล BMI และอื่น ๆ

ทำไมชุดนี้

เป็นข้อมูลจริงที่ต้อง **เตรียมก่อนใช้**: มีค่าหาย หน่วยต่างกันมาก และ positive มีเพียงราว 15%

เป็นชุดข้อมูลสำหรับการสอนที่ตัดมาจาก Framingham Heart Study ใช้ใน Lab 10 และ Lab 11 โหลดจาก `skitimo/ds351-data` commit `6cf61a3`

ขั้นที่ 1: ค่าที่หายไป

	glucose	education	BPMeds	totChol	cigsPerDay	BMI	heartRate
ค่าหาย	388	105	53	50	29	19	1

- `dropna()` เหลือ 3658 แถว ตัดทิ้ง 582 แถว (13.7%)
- positive เหลือ 557 จาก 644
- **ตรวจก่อนว่าตัดทิ้งอย่างไม่ลำเอียง**: สัดส่วน CHD ในแถวที่ตัดคือ 0.1495 ส่วนแถวที่เหลือคือ 0.1523

ถ้าสองสัดส่วนนี้ต่างกันมาก เช่น คนที่ไม่ได้วัดน้ำตาลคือคนที่ป่วยหนัก การตัดทิ้งจะทำให้ model เห็นประชากรที่ต่างจากความจริง

ขั้นที่ 2: หน่วยของตัวแปร

	mean	sd	max	odds ratio
age	49.55	8.56	70.0	1.8873 ต่อ 10 ปี
cigsPerDay	9.03	11.92	70.0	1.1962 ต่อ 10 มวน
sysBP	132.37	22.09	295.0	1.1665 ต่อ 10 mmHg
glucose	81.85	23.90	394.0	1.0739 ต่อ 10 mg/dL
male				1.7424 ชายเทียบหญิง

- สัมประสิทธิ์ต่อ 1 หน่วยมักเล็กจนอ่านไม่รู้เรื่อง เลือกหน่วยที่มีความหมาย (ต่อ 10 ปี ต่อ $1000)
- หรือ **standardize** $(x - \bar{x})/s$ แล้วอ่านเป็น “ต่อ 1 sd”

จาก model ที่ใช้ predictor ทั้ง 15 ตัว ตัวที่มีนัยสำคัญที่ระดับ 0.05 คือ `male`, `age`, `cigsPerDay`, `totChol`, `sysBP`, `glucose`

ขั้นที่ 3: ตัวแปรหมวดหมู่และ target

- target ต้องเป็น $0/1$ ไม่ใช่ `"Yes"/"No"`
- หมวดหมู่ K ระดับใช้ dummy $K-1$ ตัว เหมือนคาบที่ 6 ทุกอย่าง
- `education` ถูกเข้ารหัส $1, 2, 3, 4$: ถ้าใส่เป็นตัวเลข แปลว่ายอมรับว่าระยะห่างระหว่างระดับเท่ากัน ถ้าไม่ยอมรับ ต้องแปลงเป็น dummy
- `pd.get_dummies` คืน `bool` ต้อง `.astype(float)` ก่อนส่งให้ `statsmodels`

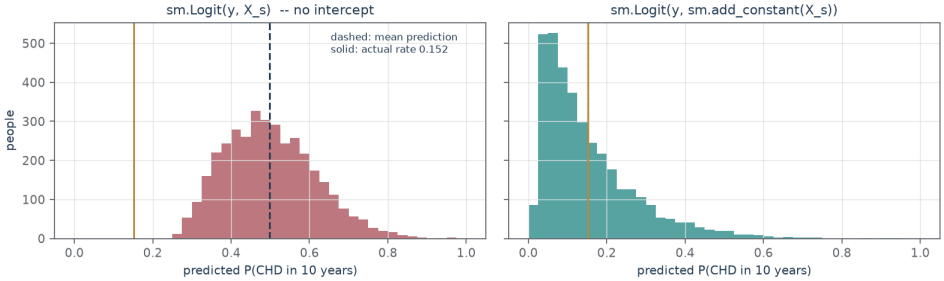
คำเตือนจากคาบที่ 6 ยังใช้ได้

intercept รวมกับ dummy ครบ K ตัวคือ dummy variable trap: design matrix ไม่เต็ม rank

กับดักใน Python

สองอย่างที่ไม่ error แต่ให้คำตอบผิด

กับดักที่ 1: `sm.Logit` ไม่ใส่ intercept ให้



	$\log \ell$	mean $\hat{p}$	$\hat{p} > 0.5$
ไม่มี constant	-2436.61	0.4987	1703
มี constant	-1377.24	0.1523	70

สัดส่วน CHD จริงคือ 0.1523 เมื่อ standardize แล้ว ทุกตัวแปรมี mean 0 ถ้าไม่มี intercept model ถูกบังคับให้ทาย $\hat{p} \approx 0.5$ ที่ค่าเฉลี่ย

แก้อย่างไร

```python
import statsmodels.api as sm

X = df.drop(columns="TenYearCHD")
Xs = (X - X.mean()) / X.std()                  # standardise

bad = sm.Logit(y, Xs).fit()                    # no intercept -- silently wrong
good = sm.Logit(y, sm.add_constant(Xs)).fit()  # the model we meant

print(bad.predict(Xs).mean())                                  # 0.4987
print(good.predict(sm.add_constant(Xs)).mean(), y.mean())  # 0.1523 0.1523
```

เมื่อ model มี intercept ค่าเฉลี่ยของ $\hat{p}$ บน training set **เท่ากับ** สัดส่วนของ $y = 1$ พอดี เป็นวิธีตรวจที่ใช้ได้ทุกครั้ง

กับดักที่ 2: optimiser หยุดก่อนถึงคำตอบ

`LogisticRegression()` ของ scikit-learn บน Framingham ที่ **ไม่ได้** standardize

	`statsmodels`	`sklearn` (ค่าเริ่มต้น)
`age`	0.0635	0.0252
`male`	0.5553	0.1451
`sysBP`	0.0154	0.0228
`glucose`	0.0071	0.0054

- ส่ง `ConvergenceWarning` และหยุดที่ 100 รอบ ซึ่งเป็น `max_iter` ค่าเริ่มต้น
- ตัวแปรที่หน่วยต่างกันมาก (`totChol` ถึง 600) ทำให้การค้นหาช้า
- **แก้ด้วยการ standardize** ก่อน ไม่ใช่ปิด warning

scikit-learn

อีกเครื่องมือหนึ่ง ที่มีค่าเริ่มต้นต่างออกไป

LogisticRegression ใน scikit-learn

```python
import numpy as np
from sklearn.linear_model import LogisticRegression

model = LogisticRegression(C=np.inf)   # C=np.inf: no penalty = maximum likelihood
model.fit(Xs, y)                       # intercept is added for you

model.intercept_, model.coef_          # beta_0 and beta_1 .. beta_p
model.predict_proba(Xs)[:, 1]          # P(y = 1 | x): column 1, not column 0
model.predict(Xs)                      # labels, using the 0.5 threshold
```

- scikit-learn ใส่ intercept ให้เอง แต่ **ไม่มี** ตาราง SE, z และ p-value
- ใช้ `statsmodels` เมื่อต้องการ **อนุมาน** และ scikit-learn เมื่อต้องการ **ทำนาย** ใน pipeline

เวอร์ชัน 1.8 ขึ้นไปเลิกใช้ `penalty=None` แล้ว (จะถูกถอดใน 1.10) ใช้ `C=np.inf` แทน

ค่าเริ่มต้นของ scikit-learn มี penalty

- `LogisticRegression()` ใช้ `C=1.0` คือ **L2 penalty** ซึ่งหดสัมประสิทธิ์เข้าหาศูนย์
- ผลลัพธ์จึง **ไม่ใช่** maximum likelihood estimate

n	CHD	สัมประสิทธิ์ age, `C=1`	สัมประสิทธิ์ age, `C=np.inf`
100	17	1.082	1.718
200	32	0.910	0.991
500	87	0.835	0.850
3658	557	ต่างกันไม่เกิน 0.0018 ทุกตัว	

ตัวอย่างสุ่มจาก Framingham ที่ standardize แล้ว `random_state=0` ข้อมูลน้อย penalty มีผลมาก ข้อมูลมาก penalty แทบไม่มีผล บน `Default` ทั้งสองแบบให้ค่าเดียวกับ `statsmodels`

จากความน่าจะเป็นสู่การจำแนก

และคำถามที่คาบหน้าจะตอบ

ตัดที่ 0.5 บน `Default`

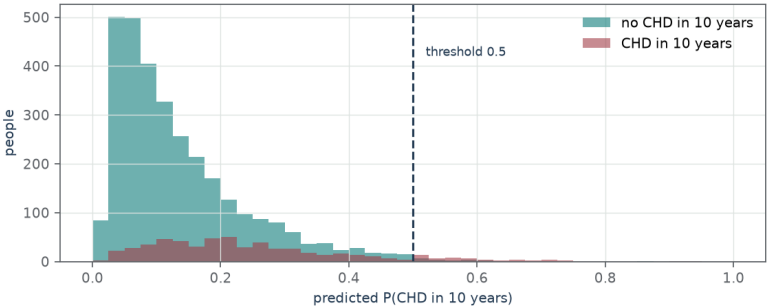
$$\hat{y} = \begin{cases} 1 & \hat{p}(x) > 0.5 \\ 0 & \text{otherwise} \end{cases}$$

- model `default ~ balance` ทาย “ผิดนัด” 142 คน ถูก 100 คน
- ผู้ที่ผิดนัดจริง 333 คน **พลาดไป 233 คน**
- accuracy $= 0.9725$

แต่ถ้าทายว่า “ไม่ผิดนัด” ทุกคน

accuracy $= 0.9667$ โดยไม่ต้องมี model เลย

ตัดที่ 0.5 บน Framingham



accuracy ของ model ที่มี 15 predictor	0.8565
accuracy ของ “ไม่เป็นโรค” ทุกคน	0.8477
ผู้ป่วยจริงที่ model จับได้	51 จาก 557 (9.2%)

model นี้มีประโยชน์ไหม

สิ่งที่ model ทำได้ดี

- สัมประสิทธิ์ตีความได้และสอดคล้องกับความรู้ทางการแพทย์
- ให้ $\hat{p}$ ที่เรียงลำดับความเสี่ยงได้

สิ่งที่ accuracy ซ่อนไว้

- ชนะการทาย “ไม่เป็นโรค” ทุกคนไม่ถึง 1%
- พลาดผู้ป่วยจริงเกิน 90%
- วัดบน training set ที่ model เห็นมาแล้ว

คาบหน้า: train/test split, confusion matrix, precision, recall, การเลือก threshold และ ROC/AUC

สรุปคาบที่ 10

1. classification ทำนาย $p(X) = \Pr(Y = 1 \mid X)$ แล้วค่อยตัดสินใจ ไม่ใช่ทำนายป้ายชื่อตรง ๆ
2. linear regression บน $Y \in \{0, 1\}$ ให้ "ความน่าจะเป็น" ติดลบได้ (3123 คนบน `Default`)
3. logistic regression: $\log\big(p/(1-p)\big) = \beta_0 + \beta_1 X_1 + \cdots$ และ $p = \sigma(\cdot)$ อยู่ใน $(0, 1)$ เสมอ
4. X เพิ่ม 1 หน่วย: log-odds เพิ่ม β_1, odds คูณ e^{β_1} แต่ p เปลี่ยนไม่เท่ากันทั้งเส้น
5. สัมประสิทธิ์หาด้วย maximum likelihood ซึ่งต้องใช้ $1 - p$ กับคนที่ $y = 0$ และไม่มีสูตรปิด
6. z-statistic อ่านเหมือน t ในคาบที่ 4
7. ใน multiple logistic regression เครื่องหมายเปลี่ยนได้เพราะ confounding (`student` กับ `balance`)
8. เตรียมข้อมูล: ค่าหาย หน่วย dummy และ target $0/1$
9. `sm.Logit` ต้อง `add_constant` เอง scikit-learn มี penalty เป็นค่าเริ่มต้น และ `ConvergenceWarning` แปลว่าคำตอบยังไม่เสร็จ
10. accuracy ที่ดูสูงอาจแค่ชนะการทายกลุ่มใหญ่ทุกคน

ปฏิบัติการที่ 10 ทำทุกขั้นบน `Default` แล้วปิดท้ายด้วย Framingham

อ่านเพิ่มเติม

James, Witten, Hastie & Tibshirani, An Introduction to Statistical Learning

- §4.1 ภาพรวมของ classification
- §4.2 ทำไมไม่ใช้ linear regression
- §4.3.1 logistic model
- §4.3.2 การประมาณสัมประสิทธิ์
- §4.3.3 การทำนาย
- §4.3.4 multiple logistic regression

คาบหน้า: §4.3.5 (มากกว่าสองกลุ่ม) และการประเมิน model จำแนกประเภท